

SAPIENZA
UNIVERSITÀ DI ROMA

Biometric Systems

Appunti del corso

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica
Corso di Laurea Magistrale in Computer Science

Docente
Prof.ssa Maria De Marsico

Appunti di
Alessio Cavedal
GitHub: https://github.com/AlessioCavedal

Anno Accademico 2026/2027

Indice

1 Introduzione ai sistemi biometrici **1**
1.1 Che cos'è la biometria 1
1.2 La biometria come problema di pattern recognition 2
1.3 Perché i sistemi biometrici 3
1.4 Architettura di un sistema biometrico 4
1.5 Verifica e identificazione 6
1.6 Utenti e contesti di acquisizione 8
1.7 Requisiti di un tratto biometrico 9
1.8 Classificazione dei tratti biometrici 10
1.9 Vantaggi e limiti della biometria 11

2 Indici di prestazione **13**
2.1 Da dove nascono gli errori 13
2.2 Confronto tra template 14
2.3 Errori e indici in verifica 16
2.4 Errori e indici in identificazione open set 19
2.5 Errori e indici in identificazione closed set 21
2.6 Attenzione alle confusioni 23

3 Valutazione offline delle prestazioni **24**
3.1 Valutazione offline 24
3.2 Organizzazione del dataset 24
3.3 Open-world e open set 26
3.4 Validazione 28
3.5 La matrice delle distanze tra probe e gallery 30
3.6 La matrice ALL-against-ALL 34
3.7 Sessioni e matrice ALL-against-ALL tra probe e gallery 40
3.8 Perché i tassi vanno calcolati bene 41

4 Affidabilità del riconoscimento **42**
4.1 Dalla matrice delle distanze alle figures of merit 42
4.2 Che cosa non dicono gli indici globali 44
4.3 Il Doddington zoo 44
4.4 Affidabilità di una singola risposta 46
4.5 Misure di qualità del campione 46
4.6 Margine dalla stima degli errori 49

4.7 System Response Reliability 49
4.8 Aggiornamento dei template 52

Capitolo 1

Introduzione ai sistemi biometrici

Questo capitolo introduce il vocabolario di base del corso: che cosa si intende per biometria, come è fatto un sistema biometrico, in quali modalità può operare e quali proprietà deve avere una caratteristica del corpo o del comportamento per poter essere usata nel riconoscimento.

1.1 Che cos'è la biometria

Il termine **biometria** viene dal greco *bíos* (vita) e *métron* (misura). In senso generale indica la misura e l'analisi statistica di dati biologici; qui interessa il senso tecnologico.

> **Definizione (biometria).** La biometria è il *riconoscimento automatico* di una persona, o la sua autenticazione, in base a caratteristiche *fisiche* e/o *comportamentali* che la distinguono dalle altre (*discriminative characteristics*).

Automatico vuol dire che il confronto lo esegue un sistema, non un esperto umano.

Tutta la biometria si regge su un'ipotesi di fondo: **ogni persona è unica**, almeno rispetto alla caratteristica che si misura. Da qui discendono tre problemi, che ritroveremo per ogni tratto biometrico:

1. individuare le caratteristiche uniche, capaci di identificare una persona;
2. trovare tecniche affidabili per misurarle;
3. progettare algoritmi affidabili che riconoscano (classifichino) una persona a partire da quelle misure.

> **Un po' di storia.** Il primo sistema di identificazione basato su misure del corpo è il *Bertillonage* (Alphonse Bertillon, polizia di Parigi, 1882), fondato su misure antropometriche come la lunghezza della testa e degli arti. Si rivelò poco affidabile, perché persone diverse potevano avere misure quasi identiche (il caso di Will West e William West, 1903), e fu soppiantato dalle impronte

digitali: Francis Galton introdusse le minuzie nel 1892, e la classificazione di Galton–Henry (1900) è ancora alla base dei sistemi usati dalle polizie di molti paesi.

1.2 La biometria come problema di pattern recognition

Un sistema biometrico è un caso particolare di sistema di **pattern recognition** (riconoscimento di forme). Ogni acquisizione (un'immagine del volto, un'impronta, un segnale vocale) viene descritta da un **feature vector**, cioè un vettore che raccoglie le caratteristiche numeriche (*feature*) estratte dal campione, una per componente. Due pattern si considerano simili se la *distanza* tra i loro feature vector è *piccola*.

Dietro questa definizione ci sono tre questioni di fondo:

- **quali feature usare**: devono catturare ciò che distingue una persona dalle altre ed essere il più possibile insensibili a ciò che cambia da un'acquisizione all'altra;
- **quale misura di distanza** (o di similarità) **adottare**: la distanza euclidea è solo una delle possibilità, e la scelta dipende da come sono fatte le feature;
- **quale margine di differenza accettare**: fino a quale distanza due campioni vanno attribuiti alla stessa persona? È la **soglia** di decisione.

La terza questione è delicata perché due acquisizioni della stessa persona non sono mai identiche. Conviene distinguere due tipi di variabilità:

- la **variabilità intra-classe**: le differenze tra campioni della *stessa* persona, dovute a posa, espressione, illuminazione, invecchiamento, pressione del dito sul sensore e così via;
- la **variabilità inter-classe**: le differenze tra campioni di persone *diverse*.

Il riconoscimento è facile quando la variabilità intra-classe è piccola rispetto a quella inter-classe: nello spazio delle feature le acquisizioni di ogni persona formano nuvole compatte e ben separate, e una soglia sulla distanza basta a distinguerle (Figura 1.1). Nella realtà le nuvole sono spesso estese e possono sovrapporsi (si pensi a due gemelli, o allo stesso volto fotografato con pose molto diverse). Allora nessuna soglia separa perfettamente i casi: una soglia troppo stretta respinge la persona giusta, una troppo larga accetta quella sbagliata. Questo compromesso è il cuore della valutazione delle prestazioni di un sistema biometrico.

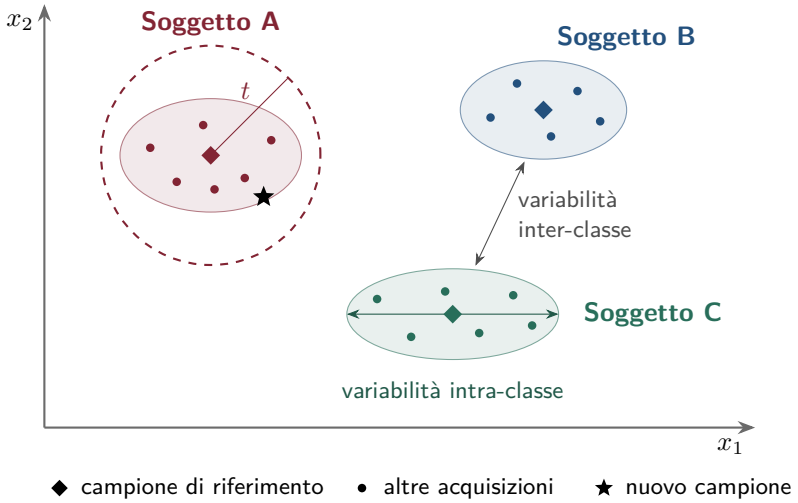


Figura 1.1. Uno spazio delle feature bidimensionale: gli assi x_1 e x_2 sono due feature. Ogni ellisse raccoglie le acquisizioni di un soggetto: la sua estensione è la variabilità intra-classe, la distanza tra le ellissi la variabilità inter-classe. Il nuovo campione è attribuito al soggetto A perché dista dal suo campione di riferimento meno della soglia t.

A seconda di che cosa rappresentano le classi, il pattern recognition affronta problemi di granularità molto diversa (Tabella 1.1). La biometria si colloca all'estremo più fine: ogni classe è una singola persona. Le classi sono quindi moltissime, tante quante le persone registrate, spesso con pochi campioni ciascuna, e le differenze tra una classe e l'altra sono sottili: tutti i volti hanno due occhi, un naso e una bocca, disposti allo stesso modo.

Tabella 1.1. Tre livelli di granularità del pattern recognition.

Problema	Le classi sono…	Il pattern deve permettere di…
Content-based image retrieval (ricerca di immagini per contenuto)	tipi di oggetti	distinguere un volto da un fiore
Riconoscimento di sottoclassi	sottoclassi di uno stesso tipo	distinguere le razze di cani
Biometria	singoli individui	distinguere una persona dalle altre

1.3 Perché i sistemi biometrici

1.3.1 Accesso fisico e accesso logico

Il riconoscimento serve quasi sempre a controllare un accesso, che può essere

- **fisico**, a una stanza, a un edificio o a un'area;
- **logico**, a risorse elettroniche o a dati critici.

1.3.2 Possesso, conoscenza e biometria

Oggi il riconoscimento, di solito a scopo di autenticazione, si basa soprattutto su due modalità, entrambe con debolezze strutturali:

- **qualcosa che si possiede** (*something you have*): una tessera, un documento, una chiave. Può essere perso, rubato o copiato, e soprattutto il sistema autentica l'*oggetto*, non chi lo presenta;
- **qualcosa che si conosce** (*something you know*): una password o un PIN, personale o condiviso. Può essere indovinato, carpito o dimenticato, e c'è un conflitto intrinseco: una password facile da ricordare è anche facile da indovinare.

La biometria aggiunge una terza modalità, **qualcosa che si è** (*something you are*): il riconoscimento si basa su una caratteristica della persona stessa, che diventa così la propria chiave (*biometric key*).

1.3.3 Integrazione con i sistemi tradizionali

Le tre modalità non si escludono a vicenda. Combinarle (**autenticazione a più fattori**) alza il livello di sicurezza, perché un attaccante deve superare tutti i fattori insieme: rubare la carta, conoscere il PIN *e* riprodurre il tratto biometrico. Come mostra la Figura 1.2, anche a parità di numero di fattori la combinazione che include la biometria è più sicura di quella tradizionale PIN + carta, perché un tratto biometrico è più difficile da sottrarre di un PIN.

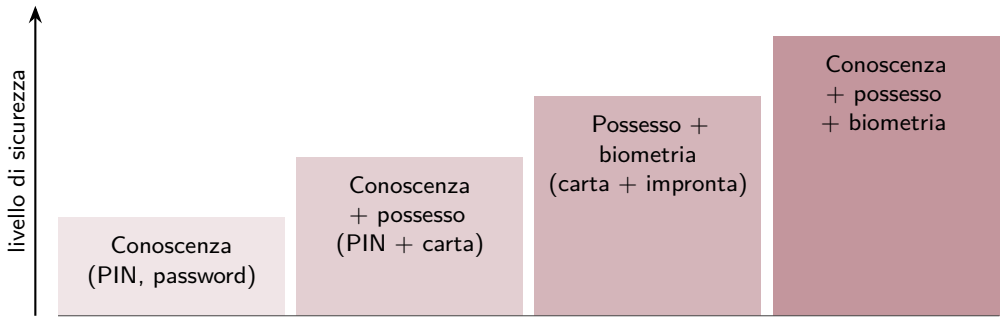


Figura 1.2. Livello di sicurezza delle diverse combinazioni di fattori di autenticazione (andamento qualitativo).

1.4 Architettura di un sistema biometrico

Un sistema biometrico lavora in due fasi distinte, schematizzate nella Figura 1.3.

> **Definizione (Enrollment).** Acquisizione ed elaborazione dei dati biometrici di un utente, perché il sistema li usi nelle successive operazioni di riconoscimento.

Durante l'enrollment (in italiano, registrazione) il sensore acquisisce un campione, cioè un'immagine o un segnale; il modulo di estrazione delle feature ne ricava il feature vector, e da questo si ottiene il *template*, che viene memorizzato nell'archivio

insieme all'identità dell'utente. Se il contesto lo consente, in questa fase si controlla anche la qualità del campione e, se non è sufficiente, si ripete l'acquisizione: un template di cattiva qualità peggiora tutti i confronti futuri.

Definizione (Riconoscimento, *recognition*). Acquisizione ed elaborazione dei dati biometrici di un utente per prendere una decisione di autenticazione, basata sul confronto (*matching*) tra il template appena calcolato e quelli memorizzati. Il confronto può essere 1:1 (verifica) o 1:N (identificazione).

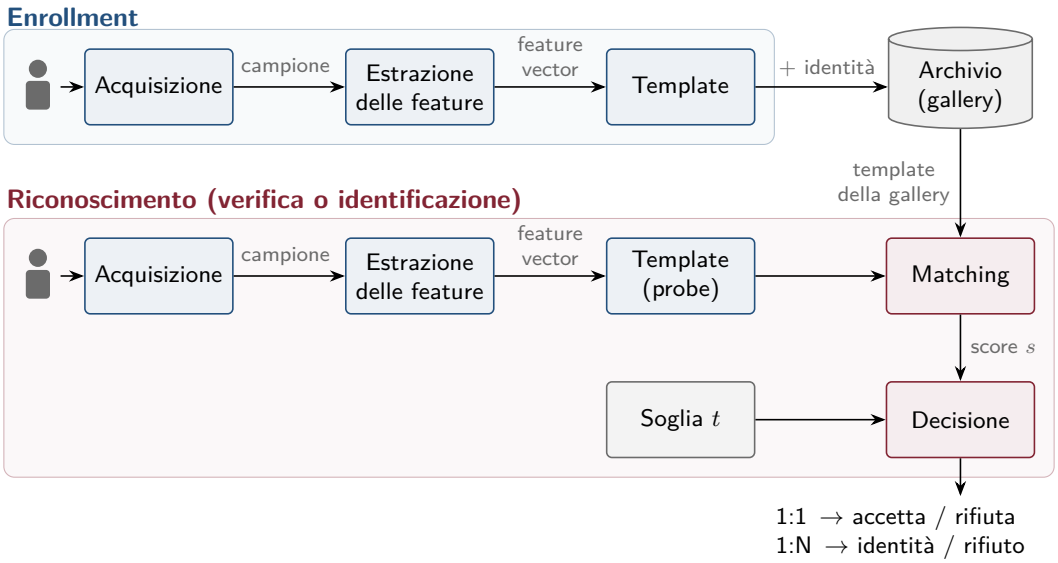


Figura 1.3. Architettura di un sistema biometrico. In enrollment il template viene memorizzato nell'archivio insieme all'identità dell'utente; nel riconoscimento il template appena calcolato (il probe) viene confrontato con quelli dell'archivio, e lo score che ne risulta viene confrontato con la soglia.

Definizione (Template, probe, gallery).

- **Template**: la rappresentazione delle feature di un campione biometrico che il sistema memorizza e confronta. Può coincidere con il feature vector o esserne una versione codificata o compressa.
- **Probe**: ogni template sottoposto al sistema per essere riconosciuto.
- **Gallery**: l'insieme degli N template dei soggetti registrati (*enrolled*), che indicheremo con $G = \{g_1, \ldots, g_N\}$.

Si memorizza il template, e non il campione grezzo, perché occupa molto meno spazio e rende i confronti più veloci; inoltre non conserva l'immagine o il segnale originale, e quindi espone meno dati personali.

1.4.1 Score e soglia

Il confronto tra un probe p e un template g_i produce un punteggio, il **matching score**, che può essere una misura di

- **similarità** $s(p, g_i)$: più è alta, più i due template si somigliano;
- **distanza** $d(p, g_i)$: più è bassa, più si somigliano.

La decisione si prende confrontando lo score con una **soglia** t (*threshold*): con una similarità il confronto ha successo se $s(p, g_i) \geq t$, con una distanza se $d(p, g_i) \leq t$. Nel seguito useremo la similarità; con una distanza basta invertire le disuguaglianze.

1.4.2 I moduli di un sistema biometrico

In genere un sistema biometrico è organizzato in quattro moduli, che nella Figura 1.3 corrispondono ai blocchi omonimi:

Modulo sensore acquisisce i dati biometrici (fotocamera, lettore di impronte, microfono, tavoletta grafica...).

Modulo di estrazione delle feature estrae dai dati acquisiti l'insieme delle caratteristiche principali; durante l'enrollment produce i template da memorizzare.

Modulo di matching confronta le feature estratte con i template memorizzati e restituisce uno o più score.

Modulo di decisione prende la decisione in base ai risultati del matching, confrontandoli con la soglia.

A questi si aggiunge l'archivio dei template, cioè il database del sistema.

1.5 Verifica e identificazione

Nella fase di riconoscimento un sistema biometrico può operare in due modalità, messe a confronto nella Figura 1.4.

1.5.1 Verifica (1:1)

In **verifica** (*verification*) l'utente *dichiara* un'identità I, ad esempio presentando un documento o un badge oppure digitando uno username. Il sistema confronta il probe solo con il template g_I associato all'identità dichiarata (confronto **1:1**) e risponde alla domanda *"sei davvero chi dichiari di essere?"*:

$$\text{decisione}(p, I) = \begin{cases} \text{accetta} & \text{se } s(p, g_I) \geq t, \\ \text{rifiuta} & \text{altrimenti.} \end{cases} \tag{1.1}$$

Se l'utente è davvero chi dichiara di essere si parla di utente **genuino** (*genuine*); se invece dichiara un'identità altrui è un **impostore** (*impostor*). Gli errori possibili sono quindi due: respingere un utente genuino (*falso rifiuto*) o accettare un impostore (*falsa accettazione*). Esempi tipici di verifica sono lo sblocco dello smartphone e i varchi automatici di frontiera, dove il passaporto elettronico fornisce sia l'identità dichiarata sia il template con cui confrontare il volto.

1.5.2 Identificazione (1:N)

In **identificazione** (*identification*) l'utente non dichiara nulla: il sistema deve stabilire a quale soggetto della gallery corrisponde il probe, confrontandolo con tutti gli N template (confronto **1:N**). Risponde alla domanda *"chi sei?"* e restituisce un'identità. Esempi: la ricerca dell'autore di un'impronta in un archivio di polizia, oppure il controllo che una persona non si sia già registrata con un altro nome, ad esempio per ottenere due volte un documento o un sussidio.

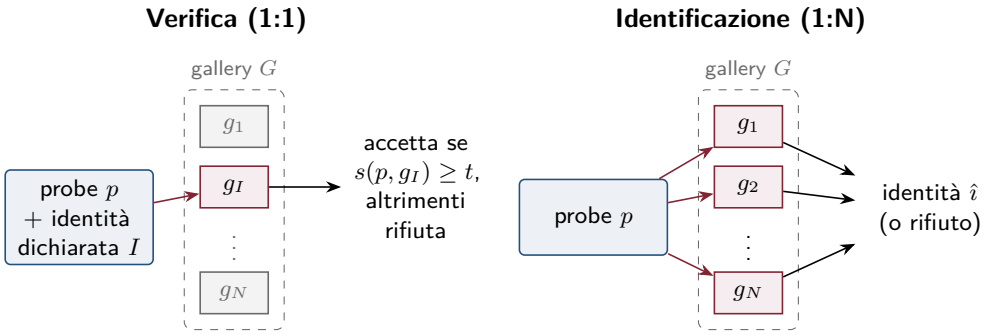


Figura 1.4. Verifica e identificazione. In verifica il probe viene confrontato solo con il template dell'identità dichiarata; in identificazione con tutti i template della gallery, e il sistema restituisce il soggetto più simile (oppure un rifiuto, se nessuno è abbastanza simile).

1.5.3 Closed set, open set e watch list

L'identificazione si declina in tre varianti, che differiscono per ciò che si sa dei probe.

Identificazione closed set (a insieme chiuso). Tutti i probe appartengono a soggetti registrati. Il sistema restituisce semplicemente il soggetto più simile: confronta il probe con tutti gli N template e sceglie l'indice i del template con lo score più alto. È ciò che indica l'operatore arg max, che restituisce il valore di i per cui $s(p, g_i)$ è massimo; l'identità restituita si scrive $\hat{\imath}$, con il cappello che la distingue dall'identità vera del probe:

$$\hat{\imath} = \arg \max_{i=1,\dots,N} s(p, g_i). \tag{1.2}$$

L'unico errore possibile è restituire l'identità sbagliata. È lo scenario tipico degli esperimenti di laboratorio, su dataset (insiemi di dati) di soggetti noti; nelle applicazioni reali è raro, perché di solito non si può escludere che si presenti qualcuno che non è registrato.

Identificazione open set (a insieme aperto). Il probe potrebbe non appartenere a nessun soggetto della gallery, quindi il sistema deve avere un'**opzione di rifiuto** (*reject option*): individua il soggetto più simile $\hat{\imath}$ come in (1.2), ma lo restituisce solo se lo score supera la soglia:

$$\text{risposta}(p) = \begin{cases} \hat{\imath} & \text{se } s(p, g_{\hat{\imath}}) \geq t, \\ \text{rifiuto (soggetto non registrato)} & \text{altrimenti.} \end{cases} \tag{1.3}$$

Gli errori possibili sono tre: respingere il probe di un soggetto registrato; accettare il probe di un soggetto non registrato, attribuendogli un'identità; restituire l'identità sbagliata per un soggetto registrato.

Watch list. Il sistema dispone di una lista di soggetti e controlla se il probe appartiene a uno di essi. È un caso particolare di open set, in cui di solito la maggior parte dei probe non è nella lista. La lista può essere una

- **white list**: i soggetti in lista ottengono l'accesso (ad esempio il personale autorizzato);
- **black list**: i soggetti in lista vengono respinti, eventualmente facendo scattare un allarme (ad esempio le persone ricercate).

La Tabella 1.2 riassume le modalità di riconoscimento.

Tabella 1.2. Modalità di riconoscimento a confronto.

Modalità	Domanda	Confronti	Risposta	Errori possibili
Verifica	"Sei chi dichiari di essere?"	1:1	accetta o rifiuta	falso rifiuto, falsa accettazione
Identificazione closed set	"Chi sei?" (il soggetto è certamente registrato)	1:N	identità	identità sbagliata
Identificazione open set	"Chi sei, ammesso che tu sia registrato?"	1:N	identità o rifiuto	falso rifiuto, falsa accettazione, identità sbagliata

1.6 Utenti e contesti di acquisizione

1.6.1 Tipologie di utenti

Le prestazioni di un sistema dipendono molto da chi lo usa. Gli utenti si caratterizzano lungo quattro dimensioni, riassunte nella Tabella 1.3.

Tabella 1.3. Le dimensioni che caratterizzano gli utenti di un sistema biometrico.

Dimensione	Significato	Conseguenze
Cooperativo / non cooperativo	L'utente cooperativo ha interesse a essere riconosciuto; quello non cooperativo è indifferente, o addirittura contrario, al riconoscimento.	Con utenti cooperativi l'impostore cerca di farsi riconoscere come un utente legittimo; con utenti non cooperativi cerca di *non* farsi riconoscere, ad esempio per sfuggire a una black list.
Pubblico / privato	Gli utenti sono clienti (pubblico) o dipendenti (privato) dell'ente che installa il sistema.	I dipendenti si possono formare e sono tenuti a usare il sistema; i clienti vanno convinti, quindi conta di più l'accettabilità.
Uso abituale / occasionale	Quanto spesso l'utente usa il sistema: più volte al giorno, ogni giorno, ogni settimana, ogni mese, di rado.	Chi lo usa spesso impara a presentarsi in modo coerente, e i suoi campioni variano meno.
Consapevole / inconsapevole	L'utente sa, oppure non sa, di essere sottoposto a riconoscimento.	Il riconoscimento inconsapevole (ad esempio da telecamere) non richiede collaborazione, ma pone problemi di privacy e avviene quasi sempre in contesti non controllati.

1.6.2 Contesti di acquisizione

Allo stesso modo si distinguono due tipi di contesto (*setting*):

- **controllato**: le condizioni di acquisizione si possono controllare e le distorsioni sono in gran parte evitate (per il volto: posa, illuminazione, espressione). I template difettosi si possono scartare e l'acquisizione si può ripetere. È il caso delle foto per i documenti o dei varchi di frontiera;
- **non controllato** (o poco controllato): le condizioni di acquisizione non si possono controllare e i template presentano distorsioni di vario grado. Quelli difettosi si possono ancora scartare, ma l'acquisizione non si può ripetere. È il caso della videosorveglianza.

Le due classificazioni sono legate: un utente cooperativo e consapevole si presta a un'acquisizione controllata, mentre utenti non cooperativi o inconsapevoli portano quasi sempre a contesti non controllati, dove la variabilità intra-classe cresce e il riconoscimento diventa molto più difficile.

1.7 Requisiti di un tratto biometrico

Non tutte le caratteristiche di una persona si prestano al riconoscimento. Un **tratto biometrico** (*biometric trait*) deve soddisfare cinque requisiti:

Universalità Ogni persona deve possedere il tratto, salvo rare eccezioni: chi ha perso le dita non ha impronte, e il sistema deve prevedere per questi casi una procedura alternativa.

Unicità Due persone qualsiasi devono essere distinguibili in base al tratto (in inglese si parla anche di *distinctiveness*).

Permanenza Il tratto non deve cambiare, o almeno non troppo, nel tempo.

Collezionabilità Il tratto deve poter essere misurato da un sensore (*collectability*).

Accettabilità Le persone coinvolte non devono avere obiezioni a farsi acquisire il tratto.

> **Approfondimento: performance e circumvention**
>
> Spesso si aggiungono altre due proprietà, che riguardano il sistema più che il tratto in sé:
>
> - **performance**: l'accuratezza e la velocità di riconoscimento raggiungibili, e le risorse necessarie per ottenerle;
> - **circumvention**: quanto è facile ingannare il sistema, ad esempio con un'impronta in silicone o con la foto di un volto.
>
> Nessun tratto soddisfa pienamente tutti i requisiti. L'iride è molto distintiva e stabile, ma richiede un sensore dedicato e la collaborazione dell'utente; il volto si acquisisce facilmente, anche a distanza, ma cambia con l'età e con l'espressione. La scelta del tratto è quindi sempre un compromesso che dipende dall'applicazione, ed è uno dei motivi per cui si combinano più tratti (sistemi *multibiometrici*).

1.8 Classificazione dei tratti biometrici

Lo standard X9.84 (2003), che fissa i requisiti minimi di sicurezza nell'uso della biometria, riconosce le tecniche della Tabella 1.4, divise in quattro categorie:

- **tratti fisiologici**: caratteristiche fisiche del corpo;
- **tratti comportamentali**: il modo in cui una persona compie un'azione;
- **tratti misti**: dipendono sia dalla fisiologia sia dal comportamento, come la voce, che dipende dalla conformazione dell'apparato vocale ma anche dal modo di parlare;
- **tracce biologiche**: il DNA.

Tabella 1.4. Tratti biometrici riconosciuti dallo standard X9.84 (2003).

Categoria	Tratto	Che cosa si misura
Fisiologici	Impronte digitali	l'andamento globale delle creste (classi *arch*, *loop*, *whorl*: arco, ansa, vortice) e le minuzie
	Iride	la tessitura dell'iride, codificata come sequenza di bit (metodo di Daugman)
	Retina	la mappa dei vasi sanguigni del fondo dell'occhio
	Volto	l'immagine del viso, nello spettro visibile o nell'infrarosso
	Orecchio	la forma del padiglione auricolare
	Mano	la geometria della mano e delle dita
Comportamentali	Firma	statica (solo l'immagine) o dinamica (traiettoria, pressione e inclinazione della penna nel tempo)
	Battitura	il ritmo con cui si premono i tasti (*keystroke dynamics*)
Misti	Voce	le caratteristiche acustiche del parlato
Tracce biologiche	DNA	la sequenza genetica: massima distintività, ma serve un'analisi di laboratorio

1.8.1 Tratti forti e tratti deboli

Un'altra distinzione riguarda il potere discriminante del tratto:

- i **tratti forti** (*strong biometric traits*), come iride, volto e impronta digitale, sono abbastanza distintivi e stabili da permettere da soli il riconoscimento;
- i **tratti deboli** (*soft biometric traits*), come il colore dei capelli, la forma del viso o l'andatura (*gait*), mancano di unicità (molte persone hanno lo stesso colore di capelli) oppure di permanenza (i tratti comportamentali risentono dell'umore, dello stato di salute e così via).

Da soli, i tratti deboli non bastano a riconoscere una persona, ma servono a *restringere la ricerca*: in identificazione permettono di scartare subito i soggetti incompatibili con il probe, riducendo il numero di confronti e quindi anche le occasioni di errore.

1.9 Vantaggi e limiti della biometria

I tratti biometrici sono un metodo di autenticazione "naturale", con vantaggi evidenti:

- non si possono perdere, prestare, rubare o dimenticare (e nemmeno cambiare, il che però è anche un limite);
- l'utente deve presentarsi di persona, quindi non può delegare l'accesso come farebbe comunicando una password.

Hanno però anche dei limiti, quasi tutti legati ai requisiti visti sopra:

- **non garantiscono un'accuratezza del 100%**: la decisione si basa su uno score e su una soglia, e anche i sistemi migliori sbagliano, soprattutto in contesti non controllati;

- **alcuni utenti non possono essere riconosciuti con alcune tecnologie** (universalità): chi fa lavori manuali pesanti, ad esempio, può avere impronte digitali danneggiate;
- **alcuni tratti cambiano nel tempo** (permanenza): il volto, per esempio, invecchia;
- **un tratto compromesso non si può sostituire**: se un tratto viene copiato, l'utente non può cambiarlo come farebbe con username e password (a meno di ricorrere alla chirurgia plastica...), per cui i template memorizzati vanno protetti con particolare cura;
- **i dispositivi possono essere inaffidabili in certe condizioni**, ad esempio con poca luce, rumore di fondo o un sensore sporco.

Capitolo 2

Indici di prestazione

Nessun sistema biometrico è infallibile. Questo capitolo mostra da dove nascono gli errori, come si confrontano due template per ottenere uno score e come si misurano gli errori nelle tre modalità di riconoscimento: verifica, identificazione open set e identificazione closed set.

2.1 Da dove nascono gli errori

Le cause principali sono già emerse nel Capitolo 1: una variabilità intra-classe ampia (posa, espressione, occhiali) e una variabilità inter-classe piccola, come tra gemelli o tra padre e figlio (Sezione 1.2); acquisizioni rumorose o distorte, come le impronte rovinate dai lavori pesanti o i volti illuminati in modo non uniforme; la mancanza di universalità (Sezione 1.7), visto che circa il 4% della popolazione ha impronte di cattiva qualità e in alcuni gruppi, come gli anziani, il problema è particolarmente diffuso. A queste cause si aggiungono gli attacchi (*spoofing*), che possono colpire il sistema in punti diversi: dal tratto contraffatto presentato al sensore, ad esempio una pellicola con l'impronta di un altro, fino alla decisione finale (Figura 2.1).

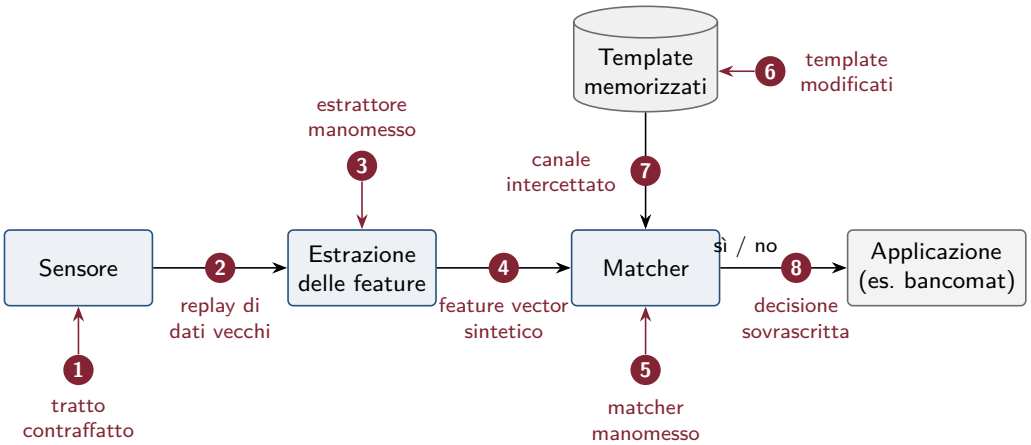


Figura 2.1. I punti in cui si può attaccare un sistema biometrico: il sensore (1), i moduli (3, 5), l'archivio dei template (6) e i canali che li collegano (2, 4, 7, 8).

2.2 Confronto tra template

Il confronto non avviene sui campioni grezzi (*sample*: un'immagine, una registrazione vocale, un'impronta...) ma sui template (Sezione 1.4), cioè sulle feature estratte dai campioni. Queste possono essere **hand-crafted**, progettate a mano da chi sviluppa il sistema, oppure apprese da una rete neurale (*learned features*). Un template può essere, ad esempio:

- un istogramma delle frequenze di valori rilevanti dell'immagine, come i livelli di grigio;
- un vettore di misure, come quelle antropometriche di Bertillon;
- una serie temporale di accelerazioni (in realtà tre, una per asse dell'accelerometro);
- un insieme di triple $\{(x_1, y_1, \theta_1), \ldots, (x_n, y_n, \theta_n)\}$ per i punti rilevanti di un'impronta: le coordinate del punto e la direzione della tangente alla cresta in quel punto.

2.2.1 Misure di similarità e di distanza

La misura con cui si confrontano due template dipende da come sono fatti.

Vettori. Se i template sono vettori di n numeri, $\mathbf{a} = (a_1, \ldots, a_n)$ e $\mathbf{b} = (b_1, \ldots, b_n)$, si può usare la **distanza euclidea**, la lunghezza del segmento che unisce i due punti: si sommano i quadrati delle differenze componente per componente e si prende la radice,

$$d(\mathbf{a}, \mathbf{b}) = \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}.$$

In alternativa si usa una similarità, la **cosine similarity** (similarità del coseno) S_C, che guarda solo la *direzione* dei due vettori e non la loro lunghezza: è il coseno dell'angolo θ tra i vettori, e vale 1 se puntano nella stessa direzione, 0 se sono perpendicolari e -1 se puntano in direzioni opposte. Si calcola dividendo il prodotto scalare $\mathbf{a} \cdot \mathbf{b}$, cioè la somma dei prodotti delle componenti, per il prodotto delle lunghezze (le norme) dei due vettori, $\|\mathbf{a}\|$ e $\|\mathbf{b}\|$:

$$S_C(\mathbf{a}, \mathbf{b}) = \cos\theta = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|} = \frac{\sum_{i=1}^{n} a_i b_i}{\sqrt{\sum_{i=1}^{n} a_i^2} \sqrt{\sum_{i=1}^{n} b_i^2}}.$$

Istogrammi e insiemi di punti. La **correlazione di Pearson** è una similarità che misura quanto due serie di valori variano insieme, cioè se dove l'una sta sopra la propria media lo sta anche l'altra. Vale tra -1 e 1: 1 se i valori salgono e scendono insieme in modo perfettamente proporzionale, 0 se non c'è alcun legame lineare, -1 se vanno in versi opposti. Date n coppie di valori corrispondenti $(x_1, y_1), \ldots, (x_n, y_n)$, ad esempio gli stessi *bin* (gli intervalli di valori) di due istogrammi, con medie $\bar{x}$ e $\bar{y}$, la correlazione r_{xy} è

$$r_{xy} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^{n} (y_i - \bar{y})^2}}.$$

Al numeratore ogni coppia contribuisce con il prodotto dei suoi scarti dalla media, positivo se i due valori stanno dalla stessa parte della propria media; il denominatore riporta il risultato tra -1 e 1.

Per gli istogrammi si usa anche la **distanza di Bhattacharyya**, che misura quanto si sovrappongono due distribuzioni. Gli istogrammi si vedono come distribuzioni di probabilità P e Q sullo stesso insieme di valori $\mathcal{X}$, i bin: $P(x)$ è la frazione dei valori che cade nel bin x. Il coefficiente di Bhattacharyya BC somma, bin per bin, la radice del prodotto delle due frequenze, e vale 1 se le distribuzioni coincidono e 0 se non hanno bin in comune. La distanza ne prende il logaritmo cambiato di segno, così vale 0 per distribuzioni identiche e cresce al diminuire della sovrapposizione:

$$D_B(P,Q) = -\ln \mathrm{BC}(P,Q), \qquad \mathrm{BC}(P,Q) = \sum_{x\in\mathcal{X}} \sqrt{P(x)\,Q(x)}.$$

Serie temporali. Due serie temporali possono avere la stessa forma ma scorrere a velocità diverse: in due ripetizioni della stessa camminata, registrate con un sistema di *motion capture* (cattura del movimento), la velocità cambia, ma i percorsi degli arti restano molto simili. Il confronto istante per istante le giudica lontane. La **Dynamic Time Warping** (DTW, deformazione dinamica del tempo) invece accoppia ogni punto di una serie con il punto corrispondente dell'altra, anche se arriva prima o dopo, e fornisce una distanza calcolata lungo questo allineamento (Figura 2.2).

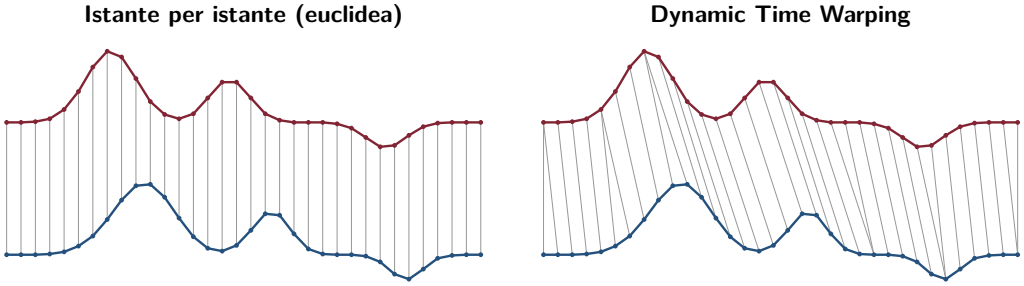


Figura 2.2. Due serie temporali con la stessa forma, la seconda in ritardo nella parte centrale. A sinistra i punti sono accoppiati istante per istante, come nella distanza euclidea; a destra la DTW accoppia ogni punto con quello corrispondente.

Feature apprese. Se il template viene da una rete di *deep learning* (apprendimento profondo), si elimina l'ultimo *layer* (strato), quello di classificazione (di solito un *softmax*), e si prendono gli *embedding*, i vettori di feature che la rete userebbe per la classificazione finale. Gli embedding si confrontano come vettori di feature hand-crafted.

Altre feature. Alcune feature richiedono un confronto più complesso: per i punti di due impronte, ad esempio, bisogna anche trovare il miglior accoppiamento tra i punti dell'una e quelli dell'altra.

La Tabella 2.1 mette a confronto queste misure.

Tabella 2.1. Le misure di confronto tra template.

Misura	Tipo	Template tipico
Distanza euclidea	distanza	vettori, anche di embedding
Cosine similarity	similarità	vettori, anche di embedding
Correlazione di Pearson	similarità	istogrammi, insiemi di punti
Distanza di Bhattacharyya	distanza	istogrammi
Dynamic Time Warping	distanza	serie temporali

In verifica e in identificazione open set lo score ottenuto viene poi confrontato con la soglia di accettazione, come si è visto nella Sezione 1.4; il ragionamento con le similarità e con le distanze è perfettamente simmetrico. La valutazione delle prestazioni analizza il comportamento del sistema, cioè i suoi errori, al variare della soglia.

2.3 Errori e indici in verifica

2.3.1 I quattro esiti

In verifica il soggetto viene accettato o respinto secondo la regola (1.1). Incrociando la decisione con la verità si hanno quattro casi, due corretti e due errori (Tabella 2.2). Sarebbe utile anche una via di mezzo, che nei casi incerti lasci la scelta a un operatore umano: la vedremo più avanti nel corso.

Tabella 2.2. I quattro esiti di una verifica. In rosso gli errori.

	Soggetto accettato	Soggetto respinto
Identità dichiarata vera (genuino)	*Genuine Acceptance* (GA), o *Genuine Match* (GM)	*False Rejection* (FR), o *False Non Match* (FNM): errore di tipo I
Identità dichiarata falsa (impostore)	*False Acceptance* (FA), o *False Match* (FM): errore di tipo II	*Genuine Reject* (GR), o *Genuine Non Match* (GNM)

2.3.2 FAR e FRR

Per confrontare i moltissimi sistemi proposti dalla ricerca bisogna misurarne le prestazioni. Il semplice conteggio degli errori non basta, perché dipende da quanti tentativi si fanno. Un **tentativo** è una singola verifica: chi si presenta dichiara un'identità, ad esempio con uno username o un badge, e fornisce il proprio tratto; il sistema lo accetta o lo respinge. Servono dei tassi.

Definizione (FAR e FRR).

- **False Acceptance Rate** (FAR), o *False Match Rate* (FMR): la percentuale dei tentativi da impostore (in cui chi si presenta dichiara un'identità che non è la sua) che il sistema accetta per errore.
- **False Rejection Rate** (FRR), o *False Non Match Rate* (FNMR): la percen-

> tuale dei tentativi genuini (in cui chi si presenta dichiara la propria identità) che il sistema respinge per errore.

Entrambi si possono esprimere come probabilità. Un FAR dello 0,1% significa che in media un impostore su 1000 riesce a violare il sistema; un FRR dello 0,05% significa che in media un utente autorizzato su 2000 non viene riconosciuto.

Si usano due tassi separati, e non un numero unico come l'accuratezza (OA, *overall accuracy*: le risposte corrette su tutte le risposte), perché ognuno guarda un solo gruppo di tentativi: il FAR solo quelli da impostore, il FRR solo quelli genuini. L'accuratezza li mette insieme, e così pesa soprattutto il gruppo più numeroso, che nei test è spesso quello degli impostori. Un sistema che respinge sempre, provato su 100 tentativi di cui 99 da impostore e 1 genuino, sbaglia solo il tentativo genuino e ha un'accuratezza del 99%. FAR e FRR mostrano invece subito il problema: il FAR è 0%, ma il FRR è 100%, perché il sistema non fa entrare nessun utente autorizzato.

2.3.3 Come si calcolano

Negli esperimenti di valutazione tutti i campioni sono etichettati con l'identità corretta (*ground truth*), cosa che durante il funzionamento reale non accade: di ogni tentativo si sa quindi se è genuino o da impostore. I probe si dividono in due insiemi:

- P_G (la G sta per gallery), i probe di soggetti presenti nella gallery: solo da qui possono venire le dichiarazioni genuine;
- P_N (la N sta per «non nella gallery»), i probe di soggetti che non sono nella gallery, ma sono nel dataset e quindi hanno comunque un'etichetta.

Quali soggetti mettere nella gallery lo si decide quando si prepara l'esperimento.

In ogni tentativo il probe dichiara un'identità e si confronta con i template che quell'identità ha nella gallery, che possono essere più d'uno: conta il miglior confronto (*match*), il topMatch. Se il suo score raggiunge la soglia di accettazione t (*threshold*) il tentativo è accettato, altrimenti è respinto, e ogni tentativo finisce in uno dei quattro esiti della Tabella 2.2. I due tassi d'errore sono

$$\mathrm{FAR}(t) = \frac{\mathrm{FA}}{\mathrm{FA} + \mathrm{GR}}, \qquad \mathrm{FRR}(t) = \frac{\mathrm{FR}}{\mathrm{FR} + \mathrm{GA}}. \tag{2.1}$$

- Una falsa accettazione può capitare solo a un impostore: accettare un utente autorizzato non è un errore. Il FAR si calcola quindi solo sui tentativi da impostore, in cui un probe dichiara un'identità della gallery diversa dalla propria. Al denominatore ci sono tutti, accettati (FA) o respinti (GR), e al numeratore quelli in cui il topMatch raggiunge la soglia.
- Un falso rifiuto può capitare solo a un genuino: respingere un impostore è giusto. Il FRR si calcola quindi solo sui tentativi genuini, in cui un probe di P_G dichiara la propria identità. Al denominatore ci sono tutti, accettati (GA) o respinti (FR), e al numeratore quelli in cui il topMatch resta sotto la soglia.

L'impostore può essere un soggetto registrato, cioè un probe di P_G che dichiara l'identità di un altro, oppure un soggetto che non è nemmeno registrato, un probe di P_N. Per il calcolo la differenza non conta: in entrambi i casi la dichiarazione è

falsa. Come si organizzano in pratica gli esperimenti e come si contano i tentativi genuini e da impostore lo vedremo nel Capitolo 3.

2.3.4 Distribuzioni degli score e soglia

La verifica si può vedere come un test di ipotesi: a ogni tentativo il sistema decide tra «stessa persona» e «persone diverse», e può sbagliare nei due modi della Tabella 2.2.

Uno score è **genuino** (*genuine*, *authentic* o *client*) se viene dal confronto tra due campioni dello stesso individuo registrato, **impostore** se viene dal confronto con il campione di un'altra persona, ad esempio non registrata. La distribuzione degli score genuini dice quanto sono frequenti i vari valori dello score nei confronti genuini; quella degli score impostori fa lo stesso per i confronti da impostore. Le due distribuzioni in genere si sovrappongono (Figura 2.3, a sinistra): alcuni impostori ottengono score più alti di alcuni genuini, e nessuna soglia li separa tutti. Fissata la soglia, il FRR è l'area della distribuzione genuina sotto la soglia, cioè la frazione dei tentativi genuini che vengono respinti; il FAR è l'area della distribuzione impostore sopra la soglia, cioè la frazione dei tentativi da impostore che vengono accettati.

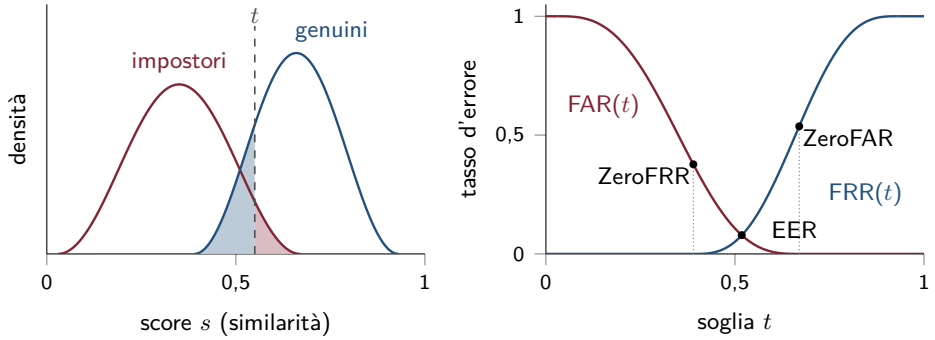


Figura 2.3. A sinistra, le distribuzioni degli score impostori e genuini: alla soglia t l'area rossa è il FAR (impostori accettati) e quella blu il FRR (genuini respinti). A destra, FAR e FRR al variare della soglia, con EER, ZeroFRR e ZeroFAR.

Spostando la soglia, i due errori variano in versi opposti (Figura 2.3, a destra). Una soglia **severa** respinge più genuini e accetta meno impostori: FRR alto e FAR basso, cioè molti errori di tipo I e pochi di tipo II. Una soglia **permissiva** fa il contrario. Con le similarità è severa una soglia alta, con le distanze una soglia bassa. Si definiscono inoltre:

- il **Genuine Acceptance Rate** (GAR), o *Genuine Match Rate* (GMR), pari a $1 - \text{FRR}$ (ovvero $1 - \text{FNMR}$);
- l'**Equal Error Rate** (EER): il tasso d'errore nel punto in cui FAR = FRR (ovvero FMR = FNMR);
- lo **ZeroFRR** (o ZeroFNMR): il FAR quando FRR = 0;
- lo **ZeroFAR** (o ZeroFMR): il FRR quando FAR = 0.

La soglia è cruciale e va scelta in base alle esigenze dell'applicazione, secondo che conti di più la sicurezza (FAR basso) o la comodità (FRR basso): anche per questo i due tassi si tengono separati. Una scelta diffusa è quella dell'EER.

2.3.5 Curve ROC e DET

Per confrontare sistemi diversi su tutte le soglie si usano due curve (Figura 2.4):

- la **ROC** (*Receiver Operating Characteristic*) riporta la probabilità di accettazione genuina, GAR $= 1 -$ FRR, al variare del FAR;
- la **DET** (*Detection Error Trade-off*) riporta la probabilità di falso rifiuto, il FRR, al variare del FAR, in scala logaritmica.

Nella ROC un sistema è tanto migliore quanto più la sua curva si avvicina all'angolo in alto a sinistra; nella DET, quanto più sta in basso. Un sistema non valido, che accetta genuini e impostori con la stessa probabilità, ha come ROC la diagonale.

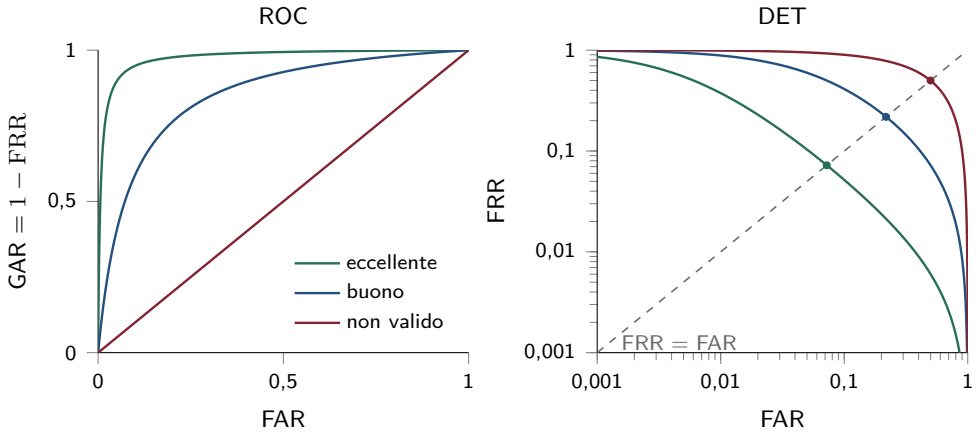


Figura 2.4. Curve ROC e DET di tre sistemi. Nella DET la bisettrice FRR = FAR incontra ogni curva nel suo EER.

2.4 Errori e indici in identificazione open set

In identificazione open set (Sezione 1.5), come in una watch list, l'individuo non dichiara un'identità: il sistema stabilisce se il suo tratto corrisponde a quello di qualcuno nella gallery. Esempi tipici sono il confronto dei passeggeri di un aeroporto con un database di terroristi, o di uno sconosciuto (un "John Doe") con un database di persone scomparse. Le domande sono due: il soggetto del probe è nel database? E chi è? Le situazioni d'errore sono quindi più numerose, e dipendono dal *matcher* (il modulo di matching) e dalla soglia.

2.4.1 Esiti possibili

Il probe viene confrontato con tutta la gallery e le identità vengono ordinate per score decrescente. Se almeno uno score raggiunge la soglia scatta un allarme (*detect*);

l'identificazione è corretta se al primo posto c'è l'identità giusta. La Tabella 2.3 riporta alcuni esempi, con una gallery di quattro soggetti.

Tabella 2.3. Esiti di un'identificazione open set con una gallery di quattro soggetti. In grassetto lo score dell'identità corretta, quando il soggetto è nella gallery.

Probe	Score in ordine	Soglia	Allarme	Esito
in P_G	**0,90** 0,86 0,60 0,40	0,85	sì	corretto: detect and identify
in P_G	**0,90** 0,86 0,60 0,40	0,95	no	errato: senza allarme il primo posto non conta
in P_G	0,86 **0,80** 0,60 0,40	0,75	sì	errato: al primo posto c'è un'altra identità
in P_N	0,80 0,70 0,60 0,40	0,85	no	corretto: nessun allarme
in P_N	0,80 0,70 0,60 0,40	0,75	sì	errato: falso allarme

Ripetendo molte prove con probe di soggetti presenti nel database (insieme P_G) si stima quanto spesso il sistema dà il risultato corretto, cioè il soggetto è nel database *e* l'individuo giusto ha lo score più alto: è il **correct detect and identify rate**. Ripetendo le prove con probe di soggetti che non sono nel database (P_N) si stima invece quanto spesso il sistema dà un allarme sbagliato: è il **false alarm rate**.

2.4.2 Indici

Il **rank** di un probe è la posizione, nella lista ordinata, del primo template della sua identità. Il **Detection and Identification Rate** al rank k, $\mathrm{DIR}(t, k)$, è la probabilità di identificazione corretta entro il rank k:

$$\mathrm{DIR}(t,k) = \frac{\text{probe identificati entro il rank } k}{|P_G|}. \tag{2.2}$$

Al denominatore c'è il numero di probe di soggetti presenti nella gallery; al numeratore quelli che hanno il primo template della propria identità entro i primi k posti, con uno score che raggiunge la soglia. Il FRR, o più precisamente **False Negative Identification Rate** (FNIR), è la probabilità di falso rifiuto:

$$\mathrm{FRR}(t) = 1 - \mathrm{DIR}(t,1).$$

Il FAR, o più precisamente **False Positive Identification Rate** (FPIR), nelle watch list anche *false alarm rate*, è la probabilità di falsa accettazione, o di falso allarme:

$$\mathrm{FAR}(t) = \frac{\text{falsi allarmi}}{|P_N|}. \tag{2.3}$$

Al denominatore c'è il numero di impostori, cioè di probe in P_N; al numeratore quelli che fanno scattare un allarme, perché almeno un template della gallery raggiunge la soglia. Infine l'EER è il valore comune che FRR e FAR assumono alla soglia in cui sono uguali.

2.4.3 Watchlist ROC e scelta della soglia

Come in verifica, vorremmo una soglia con detect and identify rate del 100% e false alarm rate dello 0%, e per le stesse ragioni non è possibile: FAR e FRR dipendono entrambi dalla soglia, ma in versi opposti. Alzando la soglia cala il detect and identify rate, ma cala anche il false alarm rate; abbassandola crescono entrambi. Riportando i detect and identify rate in funzione dei false alarm rate corrispondenti si ottiene la **watchlist ROC**, o *open-set ROC* (Figura 2.5): ogni soglia è un punto della curva.

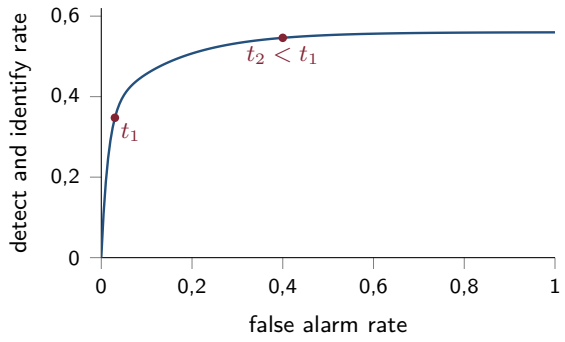


Figura 2.5. Una watchlist ROC. Ogni soglia è un punto della curva: abbassandola ($t_2 < t_1$) crescono sia il detect and identify rate sia il false alarm rate.

La soglia dipende dal tipo di applicazione; in pratica si distinguono cinque aree operative:

- **false alarm rate bassissimo**, quando ogni allarme richiede un'azione immediata, che può creare disordine e confusione tra il pubblico; inoltre l'allarme e l'intervento possono rivelare che è in corso una sorveglianza, e come, riducendo le possibilità di catturare un sospetto in futuro;
- **detect and identify rate altissimo**, quando conta soprattutto trovare chi è nella watch list: i falsi allarmi sono un problema secondario, gestito con procedure predefinite;
- **false alarm rate basso e detect and identify rate basso**: si privilegiano i pochi falsi allarmi;
- **false alarm rate alto e detect and identify rate alto**: si privilegia il detect and identify rate;
- **nessuna soglia**: l'utente vuole tutti i risultati, con le relative misure di confidenza, per condurre un'indagine.

2.5 Errori e indici in identificazione closed set

L'identificazione closed set è un caso particolare dell'open set: si sa per certo che ogni probe ha un corrispondente nel database, quindi la prima domanda (il soggetto è nel database?) ha già risposta. Resta da capire quanto il probe è vicino ai template dello stesso soggetto nella gallery. In pratica pochissime applicazioni lavorano davvero in

closed set: anche l'IAFIS (*Integrated Automated Fingerprint Identification System*) dell'FBI funziona come una watch list.

Ripetendo molte prove con soggetti diversi si stima quanto spesso l'identità corretta ha lo score più alto: è la **probabilità di identificazione al rank 1**. Se basta che sia al primo o al secondo posto, senza distinguere, si ha la probabilità di identificazione al rank 2, e così via.

Definizione (CMS e CMC).

- Il **Cumulative Match Score** al rank k, $\mathrm{CMS}(k)$, è la probabilità di identificazione al rank k, ovvero il rapporto tra i soggetti riconosciuti correttamente entro i primi k posti e il numero totale di probe, gli elementi dell'insieme P:

$$\mathrm{CMS}(k) = \frac{\text{probe riconosciuti entro il rank } k}{|P|}.$$

- La **Cumulative Match Characteristic** (CMC) è la curva dei valori di $\mathrm{CMS}(k)$ per un certo numero di rank.

Ogni rank comprende i precedenti (Figura 2.6). Se il numero di rank della curva è pari al numero di soggetti della gallery, l'ultimo valore è di sicuro 1. Il CMS(1) si chiama anche **Recognition Rate** (RR).

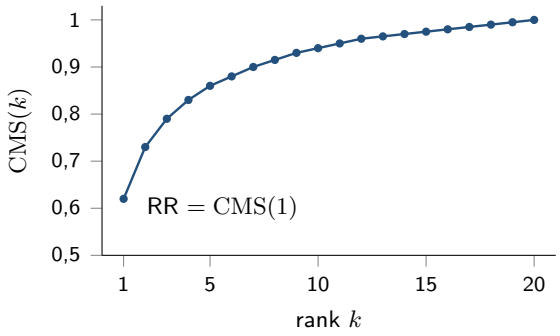


Figura 2.6. Una curva CMC per una gallery di 20 soggetti: al rank 20 l'identità corretta è di sicuro nella lista, quindi $\mathrm{CMS}(20) = 1$.

La Tabella 2.4 riassume gli indici e le curve delle tre modalità.

Tabella 2.4. Indici di prestazione e curve per modalità di riconoscimento.

Modalità	Indici	Curve
Verifica	FAR (FMR), FRR (FNMR), GAR $= 1 -$ FRR, EER, ZeroFAR, ZeroFRR	ROC, DET
Open set	$\mathrm{DIR}(t,k)$; FRR (FNIR) $= 1 - \mathrm{DIR}(t,1)$; FAR (FPIR, false alarm rate); EER	watchlist ROC
Closed set	$\mathrm{CMS}(k)$; RR $= \mathrm{CMS}(1)$	CMC

2.6 Attenzione alle confusioni

2.6.1 Indici biometrici e metriche del machine learning

Capita spesso di confondere gli indici della biometria con le metriche del machine learning (apprendimento automatico). **Precision**, **recall** e **F-score** (una combinazione delle prime due) non esprimono esattamente le stesse statistiche d'errore, che sono ciò che interessa in biometria. La precision (o *positive predictive value*) è la frazione di istanze rilevanti tra quelle restituite, la recall (o *sensitivity*) la frazione delle istanze rilevanti che sono state restituite: entrambe si basano sulla rilevanza.

Traducendo in termini biometrici, con l'accettazione come positivo (P), il rifiuto come negativo (N) e con T e F per vero e falso (*true*, *false*), si ottiene la Tabella 2.5. La recall coincide con il GAR, cioè con $1 - \text{FRR}$, e il FAR con il tasso di falsi positivi. Precision e F-score invece mescolano genuini e impostori, e hanno lo stesso difetto dell'accuratezza (Sezione 2.3.2).

Tabella 2.5. Metriche del machine learning e indici biometrici, con l'accettazione come positivo e il rifiuto come negativo: GA = TP, FA = FP, FR = FN, GR = TN.

Misura	In biometria	Nel machine learning	Altri nomi
Precision	GA/(GA + FA)	TP/(TP + FP)	*positive predictive value*
Recall	GA/(GA + FR)	TP/(TP + FN)	*sensitivity*, *true positive rate*
FRR	FR/(GA + FR)	FN/(TP + FN)	*miss rate*, *false negative rate* (FNR)
FAR	FA/(FA + GR)	FP/(FP + TN)	*fall-out*, *false positive rate* (FPR)

2.6.2 Identificazione e re-identificazione

Un'altra fonte di confusione è la **re-identificazione** (*re-identification*, re-ID). L'identificazione determina l'identità di un soggetto sconosciuto e si usa nel medio-lungo periodo. La re-identificazione associa invece la stessa persona tra telecamere o luoghi diversi, in un video, in una sequenza di immagini o in un insieme di eventi, intendendo l'identità come *presenza*: rileva e traccia la persona e le sue azioni, poi usa feature come l'aspetto, la forma del corpo o il comportamento per stabilire se la stessa identità è presente in *frame* (fotogrammi) o momenti diversi, anche in intervalli di tempo che non si sovrappongono. Si usa nel breve periodo.

La re-identificazione si valuta con metriche proprie: la CMC quando ogni *query* (ricerca) ha un solo corrispondente (*mated*) nella gallery, la mAP (*mean Average Precision*) quando ne ha più d'uno. L'AP è l'area sotto la curva precision-recall calcolata a soglie diverse, la mAP la sua media su tutte le query. I due problemi si possono anche collegare: si ritrova un soggetto più volte in un video, e poi si controlla se compare in una watch list.

Capitolo 3

Valutazione offline delle prestazioni

Il Capitolo 2 ha definito gli indici di prestazione; questo capitolo mostra come si misurano in pratica: come si prepara un esperimento su un dataset e come si contano tentativi ed errori a partire da una matrice delle distanze.

3.1 Valutazione offline

L'analisi statistica delle prestazioni si fa **offline**, su dataset "statici" raccolti apposta per valutare gli approcci a un problema. Ogni campione è etichettato con la sua identità vera, la ground truth (Sezione 2.3.3), che nel funzionamento reale non sempre si può controllare. Per questo è importante avere un test offline affidabile dell'accuratezza del sistema.

Durante la valutazione ogni campione presentato come probe può fare la parte di un genuino o di un impostore. Dipende da come è stata preparata la gallery per quell'esperimento e, in verifica, dall'identità che si fa dichiarare al probe.

3.2 Organizzazione del dataset

Un dataset biometrico contiene più campioni per ciascuna identità. Per preparare un esperimento lo si divide in parti con ruoli diversi, attraverso tre scelte successive. In ognuna conta anche *come* si divide:

- una divisione **per soggetti** decide quali soggetti compaiono in ciascuna parte, e un soggetto può mancare del tutto da una delle due;
- una divisione **per campioni** decide in quale parte va ciascun campione: i campioni di uno stesso soggetto possono finire in tutte e due le parti, ma lo stesso campione mai.

3.2.1 Training set e test set

La prima scelta separa il **training set** (TR), con cui si addestra il sistema, dal **test set** (TS), con cui lo si valuta. Insieme al training set si prepara di solito anche un

validation set (insieme di validazione): dati tenuti fuori dall'addestramento, con cui si controlla il sistema e se ne scelgono i parametri prima del test vero e proprio.

- La capacità di generalizzare di ciò che si apprende dipende dalla scelta del training set. Perché il sistema generalizzi, ad esempio, nel training set vanno inclusi template di qualità diversa, compresi quelli che portano a un riconoscimento non ovvio.
- Alcuni dataset suggeriscono una divisione precisa, perché i metodi si possano confrontare in modo equo, sugli stessi dati.
- Non tutti i metodi di riconoscimento richiedono un addestramento in senso stretto, come quello del machine learning; anche in quel caso, però, il training set serve a fissare i parametri da usare nel test.
- La divisione si fa sia per campioni sia per soggetti: un soggetto può anche mancare dal training set (Figura 3.1, a sinistra), e così si verifica meglio se il sistema generalizza a persone che non ha mai visto.

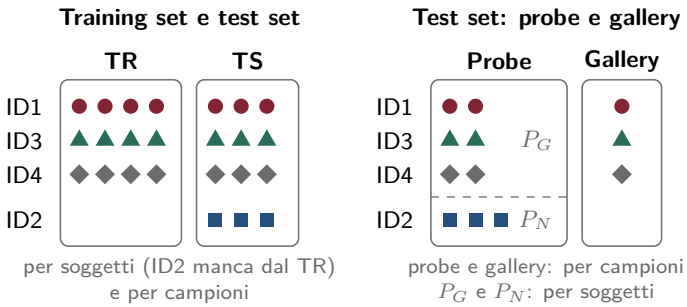


Figura 3.1. Le tre scelte su un dataset di quattro identità: ogni segno è un campione, forma e colore indicano l'identità. A sinistra il dataset diviso in training set (TR) e test set (TS): ID2 non compare nel training set. A destra il test set diviso in probe set e gallery: i probe di ID1, ID3 e ID4, che sono nella gallery, formano P_G; quelli di ID2, che non vi è, formano P_N.

3.2.2 Probe set e gallery

La seconda scelta divide il test set in **probe set** (P) e gallery (G), le due parti che servono per il test vero e proprio (Figura 3.1, a destra). La divisione si fa per campioni: un soggetto ha di solito campioni in tutte e due le parti. Un criterio tipico è mettere nella gallery i template di qualità migliore, perché l'enrollment avviene di solito in condizioni controllate (Sezione 1.6); sono possibili anche altre scelte.

3.2.3 Soggetti registrati e non registrati

La terza scelta stabilisce se i probe vengono tutti da soggetti presenti nella gallery, $P = P_G$, oppure anche da soggetti che non vi sono, $P = P_G \cup P_N$ (l'unione dei due insiemi della Sezione 2.3.3). Si fa per soggetti, e il suo effetto dipende dalla modalità:

- in *verifica* non cambia i risultati, perché è impostore chiunque dichiari un'identità non sua, che sia registrato o no;

- in *identificazione closed set* non è possibile, perché per definizione tutti i probe vengono da soggetti della gallery;
- in *identificazione open set* può influire sui risultati, secondo il rapporto tra il numero di soggetti nella gallery e il numero totale di probe. Una black list o una white list, ad esempio, può contenere pochi soggetti, mentre i probe possono essere tutti i passeggeri che entrano in un aeroporto.

La Figura 3.2 mette in fila le tre scelte.

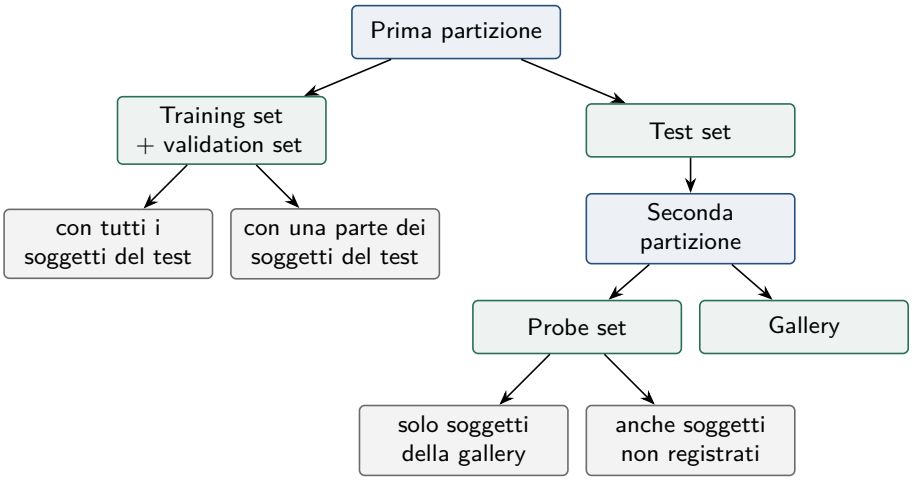


Figura 3.2. Le scelte che organizzano un esperimento. La prima partizione separa training e validation set, che possono contenere tutti i soggetti del test o solo una parte, dal test set; la seconda divide il test set in probe set e gallery, e il probe set può contenere solo soggetti della gallery o anche soggetti non registrati.

3.3 Open-world e open set

3.3.1 Open-world nel machine learning

Un modello tradizionale di machine learning vive in un mondo chiuso (*closed world*): si addestra e si prova sullo stesso insieme fisso di classi. Se nell'uso reale incontra un dato di un tipo mai visto, lo classifica male, perché lo forza in una delle categorie che conosce. L'**Open-World Machine Learning** (mondo aperto) supera questa ipotesi: il sistema riconosce ciò che conosce, ma si accorge anche di ciò che non conosce, lo gestisce e col tempo lo impara. Il suo ciclo di vita può contare su tre componenti collegati:

- **Unknown Rejection** (rifiuto dell'ignoto): il modello individua e rifiuta i dati che non appartengono a nessuna categoria nota, invece di azzardare una previsione;
- **Novelty Discovery** (scoperta della novità): il sistema analizza questi elementi sconosciuti e li raggruppa o li etichetta, per capire se formano una categoria nuova;
- **Class-Incremental Learning** (apprendimento incrementale delle classi): il modello impara le classi nuove e le aggiunge a ciò che sa, senza dimenticare

quello che ha già imparato. Il rischio di dimenticarlo si chiama *catastrophic forgetting*.

Non tutti i sistemi hanno tutti e tre i componenti, e molti si fermano al primo. È il caso dell'**Open-Set Recognition** (OSR, riconoscimento in insieme aperto): il sistema stabilisce se un dato appartiene a una classe nota, ma non prova a raggruppare gli elementi sconosciuti in classi nuove e non aggiorna il modello. Li segnala o li scarta e basta: un'auto a guida autonoma frena davanti a un oggetto che non sa identificare, senza cercare di capire di quale animale si tratta.

3.3.2 Open set nella biometria

L'identificazione biometrica open set è spesso indicata come uno dei casi d'uso più importanti dell'OSR: il sistema non può dare per scontato che il probe sia di un soggetto registrato, e deve rispondere alle due domande della Sezione 2.4, se il soggetto è nel database e chi è.

In biometria, però, open set riguarda soprattutto il rapporto tra probe e gallery: dice se alcuni probe possono non appartenere a soggetti della gallery, e non dice niente su che cosa ha visto il modello in addestramento. Le domande da farsi su un soggetto sono quindi due, e sono indipendenti:

- è stato visto nel training? Se no, è sconosciuto *al modello*;
- ha template nella gallery? Se no, è sconosciuto *al sistema biometrico*.

Lo si vede con due esperimenti diversi, che sono i due rami della prima partizione nella Figura 3.2. In tutti e due test set e gallery sono quelli della Figura 3.1: nel test ci sono ID1, ID2, ID3 e ID4, nella gallery ID1, ID3 e ID4. Cambia solo chi entra nel training (Tabella 3.1).

Tabella 3.1. Due esperimenti con lo stesso test set e la stessa gallery: cambia solo il training. Essere sconosciuti al modello ed essere sconosciuti al sistema biometrico sono due cose indipendenti.

	Esperimento 1	Esperimento 2
Soggetti nel training	ID1, ID2, ID3, ID4	ID1, ID3
Sconosciuti al modello	nessuno	ID2, ID4
Sconosciuti al sistema biometrico	ID2	ID2
Il modello fa da…	classificatore	estrattore di feature
Identificazione	open set	open set

Esperimento 1: training su tutti i soggetti. Se il sistema prevede un addestramento, lo si può fare su tutti i soggetti del dataset. Il training è allora closed set nel senso del machine learning, ma l'identificazione biometrica è open set, perché ID2 non è nella gallery. Il modello può fare da **classificatore**, cioè restituire direttamente un'identità, e l'open set si può in qualche modo simulare ignorando i risultati che riguardano le identità fuori dalla gallery, qui ID2.

Esperimento 2: training su una parte dei soggetti. Una partizione per identità, cioè una divisione per soggetti, lascia fuori dal training ID2 e ID4. Il

modello non si aggiorna e non impara niente di nuovo, ma c'è un tratto dell'open-world: nel test compaiono soggetti mai visti in addestramento. Per questo il modello non può fare da classificatore, perché restituirebbe solo le identità che ha imparato, e si usa come **estrattore di feature**, che si spera generalizzi a soggetti nuovi: riceve i campioni del test e produce i feature vector che fanno da probe o da gallery, come gli embedding della Sezione 2.2. Un soggetto sconosciuto al modello può essere noto al sistema biometrico, se ha template nella gallery come ID4, oppure sconosciuto anche a lui, come ID2. Sono quindi possibili sia l'identificazione open set sia quella closed set: con ID2 nella gallery sarebbe closed set.

3.4 Validazione

I risultati di un esperimento dipendono anche da quali elementi finiscono in ciascuna parte. In linea di principio, soprattutto quando c'è un addestramento, bisognerebbe dividere il dataset in modi diversi, ripetere la valutazione e fare la media delle prestazioni, così da evitare la distorsione (*bias*) dovuta a una divisione particolare.

3.4.1 K-fold cross validation

Un esempio è la **K-fold cross validation**. I dati si dividono in k sottoinsiemi (*fold*) e si ripete k volte il metodo *holdout*, cioè una singola divisione in training e test: ogni volta uno dei sottoinsiemi fa da test set, o validation set, e gli altri $k-1$, messi insieme, formano il training set. La stima dell'errore è la media sulle k prove. Ogni elemento finisce così nel validation set esattamente una volta e nel training set $k-1$ volte, e questo scambio di ruoli tra training e test rende il metodo più efficace. In particolare, riduce di molto

- il bias, cioè l'errore sistematico della stima, perché quasi tutti i dati si usano per l'addestramento;
- la varianza, cioè quanto la stima cambia da una divisione all'altra, perché quasi tutti i dati si usano anche per la validazione.

Per esperienza si preferisce di solito $k = 5$ oppure $k = 10$, ma il valore non è fisso.

3.4.2 Nested k-fold

Molti metodi hanno degli **iperparametri** (*hyperparameters*): valori che non si imparano dai dati ma si fissano prima dell'addestramento, ad esempio quante feature usare. Per sceglierli si provano diversi candidati e si tiene il migliore. Se però le prestazioni si misurano sugli stessi dati usati per scegliere, la stima viene troppo ottimistica, perché il candidato ha vinto proprio su quei dati.

La **nested k-fold cross validation** (k-fold annidata) tiene separate le due cose con due cicli, uno dentro l'altro (Figura 3.3):

- il *ciclo esterno* stima la capacità di generalizzare: divide tutto il dataset in fold esterni e calcola il punteggio finale su un fold rimasto fuori sia dall'addestramento sia dalla scelta;

- il *ciclo interno* sceglie gli iperparametri: divide in sotto-fold i soli dati di addestramento del ciclo esterno, e su questi confronta i candidati.



Figura 3.3. Un giro della nested k-fold dell'esempio che segue. In alto il ciclo esterno: un fold fa da test set e gli altri quattro formano il training set esterno. In basso il ciclo interno, che lavora solo su questi 96 campioni: per ogni candidato tre prove, con un sotto-fold diverso come validation set.

Esempio (5 fold esterni e 3 sotto-fold interni). Il dataset ha 120 campioni, e i candidati da provare sono 4 combinazioni di iperparametri. Il ciclo esterno fa questi passi:

1. *Dataset partition*: i 120 campioni si dividono in 5 fold da 24.
2. *Outer holdout*: un fold fa da test set finale. I suoi 24 campioni non si toccano fino al passo 4.
3. *Inner tuning*: gli altri 96 campioni, il training set esterno, passano al ciclo interno, che sceglie il candidato migliore.
4. *Outer score*: il candidato scelto si addestra sui 96 campioni e si valuta sui 24 del test set. È il punteggio di questo giro.

I passi 2–4 si ripetono 5 volte, ogni volta con un altro fold come test set, e la media dei 5 punteggi è la stima finale. Il ciclo interno, dentro il passo 3, funziona così:

a. *Sub-split*: i 96 campioni si dividono in 3 sotto-fold da 32.

b. *Grid search* (ricerca su griglia, cioè si provano tutti i candidati): ogni candidato si addestra 3 volte, ogni volta su 64 campioni, e si valuta sui 32 rimasti, che fanno da validation set.

c. *Mean validation*: per ogni candidato si fa la media dei suoi 3 punteggi.

d. *Best config*: il candidato con la media migliore torna al passo 4.

Ogni giro esterno fa $4 \cdot 3 = 12$ addestramenti nel ciclo interno più quello del passo 4. In tutto sono $5 \cdot (12 + 1) = 65$ addestramenti, contro i 5 di una k-fold semplice con gli stessi fold.

La complessità di calcolo cresce molto, e il metodo conviene soprattutto con dataset piccoli, dove non si può tenere da parte un test set fisso abbastanza grande. Il numero di fold esterni e quello di sotto-fold interni non devono coincidere. Ogni giro esterno può scegliere un candidato diverso: la media dei punteggi stima la qualità dell'intera procedura, non di un singolo modello.

3.5 La matrice delle distanze tra probe e gallery

3.5.1 La matrice

In questo capitolo si usano misure di distanza, ad esempio la distanza euclidea: un confronto ha successo se la distanza non supera la soglia, $d \leq t$ (Sezione 1.4.1). Con le similarità le considerazioni sono esattamente simmetriche.

Per ogni divisione in probe e gallery si può calcolare in anticipo una **matrice delle distanze** *probe against all gallery*: ogni riga corrisponde a un template del probe set, ogni colonna a un template della gallery, e ogni cella contiene la distanza tra i due. La stessa matrice serve a valutare ogni tipo di applicazione: verifica, identificazione closed set e open set, con uno o con più template per soggetto nella gallery. Ogni riga è un'operazione di riconoscimento sul probe che arriva, con una dichiarazione d'identità (verifica) o senza (identificazione). Ogni divisione in probe e gallery produce una matrice diversa, ed è per questo che serve la validazione.

Negli esempi che seguono, perché valgano in generale, le celle non contengono il valore della distanza ma solo il suo ordine crescente lungo la riga: 1 indica il template più vicino al probe, 2 il secondo e così via. Senza i valori non si sa se una distanza supera la soglia, quindi per ogni probe si considerano entrambi i casi. La distanza tra il probe di una riga e un template si indica con il nome del template: d(A1) è la distanza dal template A1.

Gli esempi usano un dataset con sei identità, da A a F. In verifica e in open set la gallery contiene le identità da A a D, mentre E e F fanno sempre la parte degli impostori; in closed set la gallery contiene tutte e sei le identità. Nella gallery ogni identità ha un solo template (A1, B1, ...) oppure due (A1 e A2, B1 e B2, ...). Verifica e open set usano le stesse matrici (Tabella 3.2), il closed set ne ha di proprie (Tabella 3.3).

3.5.2 Verifica

In verifica il probe si confronta solo con i template della gallery che appartengono all'identità dichiarata: non conta chi c'è nella gallery, ma quale identità si dichiara. Ogni riga della matrice è etichettata con l'identità vera del probe e con quella dichiarata. Per valutare le prestazioni bisogna separare nettamente probe e gallery, cioè usare sottoinsiemi diversi di template, e genuini e impostori.

Ogni tentativo incrementa uno dei quattro contatori della Tabella 2.2: le accettazioni genuine (GA), i falsi rifiuti (FR), le false accettazioni (FA) e i rifiuti corretti (GR). GA++ significa che il contatore GA aumenta di uno.

Tabella 3.2. Le matrici delle distanze degli esempi di verifica e di open set, in alto con un template per identità e in basso con due. Ogni cella riporta l'ordine della distanza lungo la riga. Per ogni probe sono indicate l'identità vera e quella dichiarata, che conta solo in verifica; in open set E e F sono impostori.

Probe	Identità	Dichiara	A1	B1	C1	D1
P1	A	A	1	4	2	3
P2	D	C	4	1	3	2
P3	E	D	4	2	1	3
P4	C	C		...		
P5	F	B		...		

Probe	Identità	Dichiara	A1	A2	B1	B2	C1	C2	D1	D2
P1	A	A	2	1	8	4	3	7	5	6
P2	D	C	7	6	2	1	5	8	3	4
P3	E	D	7	5	2	8	6	1	3	4
P4	C	C				...				
P5	F	B				...				

Esempio (verifica, un template per identità). Si usa la matrice in alto della Tabella 3.2. Ogni riga è una singola operazione di verifica, e conta solo la colonna dell'identità dichiarata.

- P1 è genuino: è A e dichiara A. Se $d(\text{A1}) \leq t$ si ha un'accettazione genuina, GA++; se $d(\text{A1}) > t$, un falso rifiuto, FR++.
- P2 è un impostore registrato: è D, che è nella gallery, ma dichiara un'altra identità, C. Se $d(\text{C1}) \leq t$ si ha una falsa accettazione, FA++; altrimenti un rifiuto corretto, GR++.
- P3 è un impostore non registrato: è E, che non è nella gallery, e dichiara D. Se $d(\text{D1}) \leq t$ si ha FA++, altrimenti GR++.

Il template più vicino a P2 è B1, ma in verifica non conta: si guarda solo il template dell'identità dichiarata.

Con più template per identità il probe si confronta con tutti i template dell'identità dichiarata e si sceglie il risultato migliore, cioè la distanza più piccola: è il topMatch della Sezione 2.3.3.

Esempio (verifica, due template per identità). Si usa la matrice in basso della Tabella 3.2.

- P1, genuino (A dichiara A): tra A1, di ordine 2, e A2, di ordine 1, il miglior risultato è A2. Se $d(\text{A2}) \leq t$ si ha GA++, altrimenti FR++.
- P2, impostore registrato (D dichiara C): il miglior risultato per C è C1. Se $d(\text{C1}) \leq t$ si ha FA++, altrimenti GR++.
- P3, impostore non registrato (E dichiara D): il miglior risultato per D è

D1. Se $d(\text{D1}) \leq t$ si ha FA++, altrimenti GR++.

Avere più campioni per soggetto fa diminuire il tasso di falsi rifiuti (FRR, *False Rejection Rate*), perché un genuino ha più possibilità di trovare un proprio template vicino, ma può anche far aumentare quello di false accettazioni (FAR, *False Acceptance Rate*), perché un impostore ha più possibilità di somigliare a uno dei template di un genuino.

Per ottenere un risultato medio affidabile servono abbastanza valutazioni. Ogni volta probe set e gallery si scelgono in modo diverso, e ogni volta può cambiare quanti genuini e quanti impostori si considerano. Anche la scelta di genuini e impostori può influire sul risultato, come si vedrà più avanti con il *Doddington zoo*.

3.5.3 Identificazione open set

In open set il probe si confronta con tutti i template della gallery. Qui conta chi c'è nella gallery, perché manca una dichiarazione d'identità: ogni riga è etichettata solo con l'identità vera del probe. Sono genuini i probe delle identità presenti nella gallery, impostori quelli delle identità che non vi sono. Anche qui bisogna separare nettamente probe e gallery, e genuini e impostori.

Per ogni probe si ordinano i template della gallery per distanza crescente:

- per un probe genuino si cerca il primo template della sua identità. Se è al posto k della lista e la sua distanza è entro la soglia, il probe è identificato correttamente al rank k (il rank si conta sui template, come nella Sezione 2.4). Il contatore $\text{DI}(t, k)$, da *detect and identify*, conta questi probe per ogni posizione k. Diviso per il numero di probe genuini, e sommato su tutte le posizioni fino a k, dà il *Detection and Identification Rate* $\text{DIR}(t, k)$, la probabilità di identificazione corretta entro il rank k. I falsi rifiuti non si registrano, perché il FRR si ricava come $1 - \text{DIR}(t, 1)$;
- per un probe da impostore basta il primo template della lista: se è entro la soglia scatta un falso allarme, FA++, altrimenti l'impostore è respinto correttamente, GR++.

Esempio (open set, un template per identità). Si usa la matrice in alto della Tabella 3.2, ignorando le dichiarazioni: ogni riga è una singola operazione di identificazione. P1 è A, P2 è D, P3 è E, un impostore.

- P1: la lista ordinata è A1, C1, D1, B1, con l'identità giusta al primo posto. Se $d(\text{A1}) \leq t$ si ha $\text{DI}(t, 1)$++; altrimenti è un falso rifiuto, che non si registra.
- P2: la lista è B1, D1, C1, A1, con un'identità sbagliata al primo posto. Se $d(\text{B1}) \leq t$ il sistema restituisce B, e al primo posto è un fallimento (un falso rifiuto, che non si registra); se però anche $d(\text{D1}) \leq t$, il probe contribuisce a $\text{DI}(t, 2)$. Il secondo controllo ha senso solo se $d(\text{B1}) \leq t$, perché D1 è più lontano di B1. Se $d(\text{B1}) > t$ nessun template è entro la soglia: falso rifiuto, non registrato.

- P3, impostore: la lista è C1, B1, D1, A1. Se $d(\text{C1}) \leq t$ scatta un falso allarme, FA++; altrimenti l'impostore è respinto, GR++.

Esempio (open set, due template per identità). Si usa la matrice in basso della Tabella 3.2.

- P1 (A): la lista è A2, A1, C1, B2, D1, D2, C2, B1. Se $d(\text{A2}) \leq t$ si ha $\text{DI}(t, 1)$++, altrimenti un falso rifiuto. Rispetto all'esempio precedente il template A2 è più vicino al probe: avere più template dà più possibilità di riconoscimento corretto.
- P2 (D): la lista è B2, B1, D1, D2, C1, A2, A1, C2. Se $d(\text{B2}) \leq t$ è un fallimento al primo posto, e se anche $d(\text{D1}) \leq t$ il probe contribuisce a $\text{DI}(t, 3)$, e quindi al DIR dal rank 3 in su, perché il primo template di D è il terzo della lista. Se $d(\text{B2}) > t$ è un falso rifiuto.
- P3 (E, impostore): la lista è C2, B1, D1, D2, A2, C1, A1, B2. Se $d(\text{C2}) \leq t$ si ha FA++, altrimenti GR++.

Come in verifica servono abbastanza valutazioni, ogni volta con probe set e gallery scelti in modo diverso e con una diversa distribuzione di genuini e impostori, perché anche qui quella scelta può influire sul risultato.

3.5.4 Identificazione closed set

In closed set il probe si confronta con tutti i template della gallery, e ogni riga è etichettata con la sua identità vera, senza dichiarazione. Tutte le identità sono nella gallery, quindi non compaiono impostori e non c'è una soglia di accettazione. Per valutare le prestazioni basta separare nettamente probe e gallery.

Per ogni probe si guarda in quale posizione k della lista ordinata compare il primo template della sua identità. Il probe contribuisce al *Cumulative Match Score* $\text{CMS}(k)$ e, poiché il CMS è cumulativo (Sezione 2.5), anche a tutti i rank successivi: si dice che contribuisce a $\text{CMS}(k)$ «e oltre».

Esempio (closed set, un template per identità). Si usa la matrice in alto della Tabella 3.3.

- P1 (A): la lista è A1, C1, D1, B1, F1, E1. L'identità al primo posto è quella giusta: il probe contribuisce a CMS(1), cioè al recognition rate.
- P2 (D): la lista è B1, D1, E1, C1, F1, A1. Al primo posto c'è un'identità sbagliata, quella giusta è al secondo: il probe contribuisce a CMS(2) e oltre.
- P3 (E): la lista è C1, B1, D1, E1, A1, F1. L'identità giusta è al quarto posto: il probe contribuisce a CMS(4) e oltre.

Tabella 3.3. Le matrici delle distanze degli esempi di closed set, in alto con un template per identità e in basso con due. Tutte le identità sono nella gallery; ogni cella riporta l'ordine della distanza lungo la riga.

Probe	Identità	A1	B1	C1	D1	E1	F1
P1	A	1	4	2	3	6	5
P2	D	6	1	4	2	3	5
P3	E	5	2	1	3	4	6
P4	C			...			
P5	F			...			

Probe	Identità	A1	A2	B1	B2	C1	C2	D1	D2	E1	E2	F1	F2
P1	A	2	1	8	11	5	7	6	12	10	3	9	4
P2	D	11	3	2	7	8	10	5	1	6	12	9	4
P3	E	9	10	4	7	2	3	12	5	6	8	11	1
P4	C						...						
P5	F						...						

Esempio (closed set, due template per identità). Si usa la matrice in basso della Tabella 3.3.

- P1 (A): la lista è A2, A1, E2, F2, C1, D1, C2, B1, F1, E1, B2, D2. Al primo posto c'è l'identità giusta: il probe contribuisce a CMS(1).
- P2 (D): la lista è D2, B1, A2, F2, D1, E1, B2, C1, F1, C2, A1, E2. Ora al primo posto c'è l'identità giusta, grazie al nuovo template D2: il riconoscimento è migliorato e il probe contribuisce a CMS(1).
- P3 (E): la lista è F2, C1, C2, B1, D2, E1, B2, E2, A1, A2, F1, D1. Il primo template di E è al sesto posto: il probe contribuisce a CMS(6). Qui il riconoscimento è peggiorato, per colpa dei template aggiunti alle altre identità.

Anche in closed set servono abbastanza valutazioni, ogni volta con probe set e gallery scelti in modo diverso.

3.6 La matrice ALL-against-ALL

3.6.1 L'idea

Statistiche più complete si ottengono con una matrice delle distanze **ALL-against-ALL**, in cui ogni template del dataset si confronta con tutti gli altri: fa da probe nella sua riga e da template della gallery nella sua colonna. Le celle della diagonale, che confrontano un template con se stesso, non si considerano; tutte le altre sono confronti validi, qualunque sia il tipo di test (Figura 3.4).

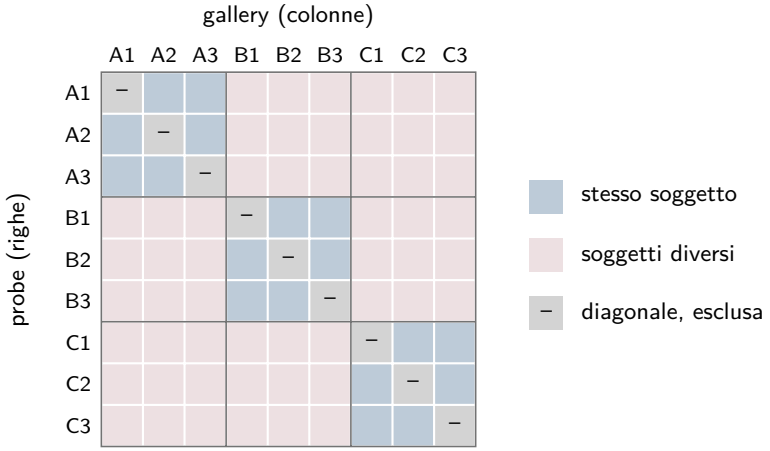


Figura 3.4. La matrice ALL-against-ALL di un dataset con tre soggetti (A, B, C) e tre template ciascuno. Ogni cella è un confronto valido, tranne quelle della diagonale; i colori distinguono i confronti tra template dello stesso soggetto da quelli tra soggetti diversi.

Le distanze si calcolano una volta per tutte e si usano in modo diverso secondo la modalità e il numero di template per soggetto nella gallery. Ogni riga si considera a turno genuina o da impostore, e può contribuire più volte, tante quanti sono gli esperimenti che può rappresentare: è un singolo test o un insieme di test, secondo la modalità. I risultati si accumulano, e i tassi che si ottengono sono medie che comprendono molte possibili divisioni in probe e gallery. Per semplicità si assume che ogni soggetto abbia lo stesso numero di campioni; estendere i calcoli al caso generale è immediato.

Si distinguono inoltre il caso **single-template** e il caso **multiple-template**, secondo quanti campioni per soggetto si assume che contenga la gallery di test. La notazione è questa:

- N è il numero di soggetti e S il numero di template per soggetto;
- $|G| = S \cdot N$ è il numero totale di campioni, cioè di righe e di colonne della matrice (le barre $|\cdot|$ indicano il numero di elementi di un insieme);
- M è la matrice delle distanze e $M_{i,j}$ la cella della riga i e della colonna j: la distanza tra il template della riga i, che fa da probe, e quello della colonna j, che fa da template della gallery. Nel Capitolo 2 l'indice j indicava il probe; qui indica la colonna;
- $\mathrm{id}(i)$ e $\mathrm{id}(j)$ sono le identità vere (ground truth), o etichette (*label*), dei template della riga i e della colonna j;
- TG e TI sono i numeri totali di tentativi genuini e da impostore, che servono come denominatori dei tassi. Per ogni procedura si possono calcolare con una formula, oppure contare durante la scansione della matrice.

Nella Figura 3.4, ad esempio, $N = 3$, $S = 3$ e $|G| = 9$.

3.6.2 Verifica single-template

In verifica single-template ogni cella fuori dalla diagonale è un tentativo di verifica a sé: è come se il probe della riga i dichiarasse l'identità del template della colonna j, e si confrontano solo loro due (Figura 3.5, in alto). Se le due identità vere coincidono il tentativo è genuino, altrimenti è da impostore. Ogni riga è quindi un insieme di $|G| - 1$ operazioni, tutte le colonne tranne la diagonale:

- $S - 1$ tentativi genuini, con gli altri template dello stesso soggetto;
- $(N-1) \cdot S$ tentativi da impostore, con tutti i template degli altri $N-1$ soggetti.

Sommando sulle $|G|$ righe, i tentativi genuini sono in tutto $\mathrm{TG} = |G| \cdot (S-1)$ e quelli da impostore $\mathrm{TI} = |G| \cdot (N-1) \cdot S$.

Per ogni soglia si scorrono tutte le celle e per ognuna si incrementa uno dei quattro contatori: se la distanza è entro la soglia il tentativo è accettato, e l'accettazione è genuina (GA) o falsa (FA) secondo le identità; se la supera è respinto, e il rifiuto è falso (FR) o corretto (GR). Alla fine i contatori dei genuini si dividono per TG e quelli degli impostori per TI. Oltre al tasso di accettazioni genuine (GAR, *Genuine Acceptance Rate*), al FRR e al FAR si ottiene il **Genuine Reject Rate** (GRR), la frazione dei tentativi da impostore respinti correttamente, che è pari a $1 - \mathrm{FAR}$.

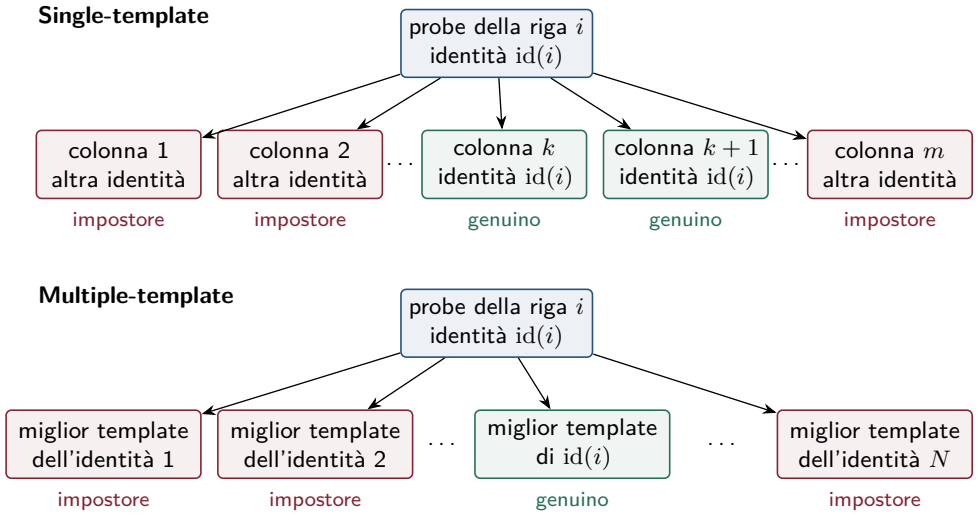


Figura 3.5. In verifica ogni riga della matrice ALL-against-ALL è un insieme di test in parallelo, genuini (in verde) o da impostore (in rosso). In alto, single-template: un tentativo per ogni colonna tranne la diagonale (m è l'ultima colonna). In basso, multiple-template: un tentativo per ogni identità, con il miglior template di quell'identità.

Pseudocodice (verifica single-template).

```
for each soglia t
    azzera i contatori GA, FA, FR, GR
    for each cella M_{i,j} con i ≠ j
        if M_{i,j} ≤ t then
            if id(i) = id(j) then GA++ else FA++
        else
            if id(i) = id(j) then FR++ else GR++
    GAR(t) = GA/TG,    FRR(t) = FR/TG
    FAR(t) = FA/TI,    GRR(t) = GR/TI
```

3.6.3 Verifica multiple-template

In verifica multiple-template il probe della riga i dichiara a turno ciascuna delle N identità. Per ognuna lo si confronta con tutti i template di quell'identità, escluso se stesso, e si tiene il risultato migliore, cioè la distanza minima (Figura 3.5, in basso). Le celle della riga si raggruppano quindi per identità della colonna, e ogni gruppo dà un solo tentativo. Ogni riga è un insieme di N operazioni: un tentativo genuino, con il gruppo della propria identità, e $N-1$ tentativi da impostore. In totale $\mathrm{TG} = |G|$ e $\mathrm{TI} = |G| \cdot (N-1)$.

Pseudocodice (verifica multiple-template).

```
for each soglia t
    azzera i contatori GA, FA, FR, GR
    for each riga i
        for each identità I                          ▷ I è l'identità dichiarata
            dist = minimo delle celle M_{i,j} con id(j) = I e j ≠ i
            if dist ≤ t then
                if id(i) = I then GA++ else FA++
            else
                if id(i) = I then FR++ else GR++
    GAR, FRR, FAR e GRR come nella verifica single-template
```

Al posto del minimo si può usare la media delle distanze del gruppo. Questo può aumentare l'accuratezza, perché il criterio è più restrittivo: un impostore, per essere accettato, deve essere vicino in media a tutti i template dell'identità dichiarata, non a uno solo. Si perdono però alcuni vantaggi dell'approccio multiple-template, in cui a un genuino basta somigliare a uno dei propri template.

3.6.4 Identificazione open set

Per l'identificazione si considera solo il caso multiple-template, per non complicare troppo lo pseudocodice. Con un solo template per soggetto, infatti, bisognerebbe scegliere quale template di ogni soggetto mettere nella gallery, e trattandosi di un'identificazione andrebbero considerate tutte le scelte possibili, ciascuna con il proprio ordinamento.

Nella riga i si ordinano per distanza crescente tutte le celle tranne quella della diagonale. Si ottiene la lista dei candidati $L_1 \le L_2 \le \cdots \le L_{|G|-1}$, dove L_1 è la

distanza dal template più vicino, L_2 dal secondo e così via. Ogni riga è un insieme di due operazioni di identificazione in parallelo (Figura 3.6):

- un tentativo *genuino*, in cui il soggetto id(i) si considera registrato, con i suoi altri template nella gallery;
- un tentativo da *impostore*, in cui il soggetto si considera non registrato. Il probe si confronta solo con i template della gallery, quindi i template della sua identità non devono comparire nella lista: si saltano.

La lista ordinata è la stessa per i due tentativi. In totale $\mathrm{TG} = \mathrm{TI} = |G|$.

Tutto dipende dal primo template della lista. Se è entro la soglia ci sono due casi:

- il primo template è dell'identità giusta: il genuino è identificato al primo posto, $\mathrm{DI}(t, 1)$++. Per l'impostore in parallelo si saltano i template della sua identità e si guarda il primo di un'altra identità: se è entro la soglia, FA++, altrimenti GR++;
- il primo template è di un'altra identità: il genuino fallisce al primo posto, ma se più avanti, alla posizione k, c'è un template della sua identità entro la soglia, si ha $\mathrm{DI}(t, k)$++. L'impostore in parallelo produce di sicuro un falso allarme, FA++, perché il primo template è già di un'altra identità ed è entro la soglia: non c'è niente da saltare.

Se invece nemmeno il primo template è entro la soglia, non lo è nessuno: l'impostore è respinto correttamente, GR++, mentre per il genuino è un falso rifiuto, che non si conta perché il FRR si ricava da $\mathrm{DIR}(t, 1)$. Alla fine i tassi del rank 1 si calcolano direttamente, e quelli dei rank successivi si accumulano: $\mathrm{DIR}(t, k)$ è $\mathrm{DIR}(t, k-1)$ più la frazione di genuini identificati esattamente al rank k.

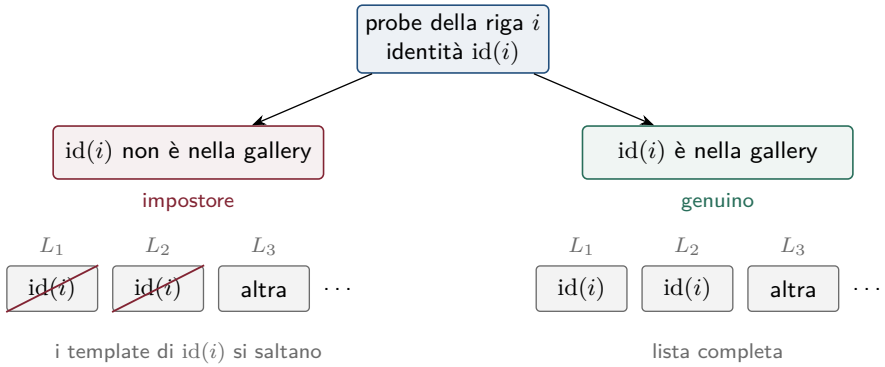


Figura 3.6. In identificazione open set ogni riga della matrice ALL-against-ALL fa due operazioni in parallelo sulla stessa lista ordinata. Il genuino considera il proprio soggetto registrato e usa la lista completa; l'impostore lo considera non registrato e ne salta i template.

Pseudocodice (identificazione open set multiple-template).

for each soglia t
  azzera i contatori FA, GR e $\mathrm{DI}(t,k)$ per ogni k
  for each riga i
    ordina le celle $M_{i,j}$ con $j \neq i$: $L_1 \leq \cdots \leq L_{|G|-1}$
    if $L_1 \leq t$ **then** ▷ potenziale accettazione
      if L_1 è un template di $\mathrm{id}(i)$ **then**
        $\mathrm{DI}(t,1)$++ ▷ genuino identificato
        k = prima posizione con un'identità diversa da $\mathrm{id}(i)$
        if $L_k \leq t$ **then** FA++ **else** GR++ ▷ impostore
      else
        k = prima posizione con un template di $\mathrm{id}(i)$
        if $L_k \leq t$ **then** $\mathrm{DI}(t,k)$++ ▷ genuino al rank k
        FA++ ▷ impostore
    else
      GR++ ▷ il FR si ricava dal DIR
  $\mathrm{DIR}(t,1) = \mathrm{DI}(t,1)/\mathrm{TG}, \quad \mathrm{FRR}(t) = 1 - \mathrm{DIR}(t,1)$
  $\mathrm{FAR}(t) = \mathrm{FA}/\mathrm{TI}, \quad \mathrm{GRR}(t) = \mathrm{GR}/\mathrm{TI}$
  for each rank $k = 2, \ldots, |G| - 1$
    $\mathrm{DIR}(t,k) = \mathrm{DIR}(t,k-1) + \mathrm{DI}(t,k)/\mathrm{TG}$

3.6.5 Identificazione closed set

Anche in closed set si considera solo il caso multiple-template. Ogni riga è una sola operazione con un tentativo genuino: il soggetto è sempre registrato, non si assumono tentativi da impostore e non si usa una soglia di accettazione. I tentativi in tutto (*total attempts*) sono $\mathrm{TA} = |G|$. Per ogni riga si cerca la posizione k del primo template della propria identità nella lista ordinata e si incrementa il contatore $C(k)$, che conta i probe riconosciuti esattamente al rank k. Alla fine i contatori si dividono per TA e si accumulano: CMS(1) è il recognition rate (RR), e ogni CMS(k) aggiunge al precedente la frazione di probe riconosciuti esattamente al rank k.

Pseudocodice (identificazione closed set multiple-template).

for each riga i
  ordina le celle $M_{i,j}$ con $j \neq i$: $L_1 \leq \cdots \leq L_{|G|-1}$
  k = prima posizione con un template di $\mathrm{id}(i)$
  $C(k)$++
$\mathrm{CMS}(1) = C(1)/\mathrm{TA}, \quad \mathrm{RR} = \mathrm{CMS}(1)$
for each rank $k = 2, \ldots, |G| - 1$
  $\mathrm{CMS}(k) = \mathrm{CMS}(k-1) + C(k)/\mathrm{TA}$

3.6.6 Pro e contro

Il calcolo ALL-against-ALL ha due vantaggi:

- è facile da programmare e, in pratica, calcola una sorta di media su tutte le possibili distribuzioni di tentativi genuini e da impostore;

- i tentativi da impostore sono sempre molti più di quelli genuini, e questo permette di mettere sotto sforzo il sistema, per valutarlo in situazioni con moltissimi tentativi da impostore.

E due svantaggi:

- il tempo per calcolare la matrice completa può diventare molto alto, perché ogni template va confrontato con tutti gli altri;
- non permette di analizzare distribuzioni specifiche di tentativi genuini e da impostore, che possono dare risultati particolari.

3.7 Sessioni e matrice ALL-against-ALL tra probe e gallery

Il calcolo ALL-against-ALL è adatto quando tra i template di uno stesso soggetto non c'è un intervallo di tempo noto o rilevante. Quando invece i campioni sono divisi in **sessioni**, acquisite in momenti diversi che non si sovrappongono, è più corretto costruire probe set e gallery con template di sessioni diverse. Il motivo è che i campioni di uno stesso soggetto acquisiti nella stessa sessione si somigliano di solito più di quelli di sessioni diverse, per le variazioni che avvengono nel tempo (piccoli cambiamenti del volto), nelle condizioni dell'ambiente (l'illuminazione) e nel funzionamento del sensore (lo sporco che si deposita su un lettore di impronte). Confrontando campioni della stessa sessione, le prestazioni complessive sembrerebbero migliori.

Anche in questo caso si possono calcolare statistiche estese con una matrice completa, *ALLPROBE-against-ALLGALLERY*, in cui ogni template del probe set si confronta con tutti i template della gallery. Strategia, vantaggi e svantaggi sono gli stessi della matrice ALL-against-ALL; in più può essere utile creare divisioni diverse in probe e gallery e fare la media dei risultati.

Cambia invece la forma della matrice. Le righe sono i $|P|$ template del probe set, le colonne i $|G|$ template della gallery; tutti gli N soggetti contribuiscono sia al probe set sia alla gallery, e senza perdere in generalità si può assumere che ognuno abbia S template in ciascuno dei due, così che $|G| = |P| = S \cdot N$. Probe e template della gallery sono sempre campioni diversi, quindi non c'è una diagonale da escludere: lo pseudocodice è lo stesso della Sezione 3.6, ma si usano tutte le celle della riga e la lista ordinata ha $|G|$ elementi. Per la stessa ragione cambiano i conteggi dei tentativi (Tabella 3.4): in verifica single-template, ad esempio, ogni riga ha S tentativi genuini invece di $S - 1$, perché nessun template della gallery coincide con il probe.

Tabella 3.4. Tentativi contenuti in ogni riga e tentativi totali, genuini (TG) e da impostore (TI), nelle due matrici. In closed set non ci sono impostori, e il totale dei tentativi si indica con TA.

Procedura	ALL-against-ALL ($\|G\|$ righe)	Tra probe e gallery ($\|P\|$ righe)
Verifica single-template	per riga $S-1$ genuini e $(N-1)\cdot S$ impostori; TG $= \|G\| \cdot (S-1)$, TI $= \|G\| \cdot (N-1) \cdot S$	per riga S genuini e $(N-1)\cdot S$ impostori; TG $= \|P\| \cdot S$, TI $= \|P\| \cdot (N-1) \cdot S$
Verifica multiple-template	per riga 1 genuino e $N-1$ impostori; TG $= \|G\|$, TI $= \|G\| \cdot (N-1)$	per riga 1 genuino e $N-1$ impostori; TG $= \|P\|$, TI $= \|P\| \cdot (N-1)$
Open set (multiple-template)	per riga 1 genuino e 1 impostore; TG $=$ TI $= \|G\|$	per riga 1 genuino e 1 impostore; TG $=$ TI $= \|P\|$
Closed set (multiple-template)	per riga 1 tentativo genuino; TA $= \|G\|$	per riga 1 tentativo genuino; TA $= \|P\|$

3.8 Perché i tassi vanno calcolati bene

Calcolare i tassi nel modo corretto è essenziale. Si pensi a un esperimento di verifica con 100 probe, in cui il sistema accetta per errore 10 impostori e respinge per errore 10 utenti genuini. Dividendo gli errori per il numero totale di probe si otterrebbe FAR = FRR = 10/100, qualunque sia la composizione dei probe. Il ragionamento però trascura quanti sono davvero gli impostori e quanti gli utenti genuini: un tasso d'errore è il numero di risposte sbagliate rispetto a quelle date *allo stesso tipo di utenti*. Il FRR va diviso per il numero di tentativi genuini, il FAR per il numero di tentativi da impostore (Sezione 2.3). La Tabella 3.5 mostra tre composizioni possibili dei 100 probe.

Tabella 3.5. Lo stesso numero di errori su 100 probe, con tre composizioni diverse di genuini e impostori. In rosso i casi in cui il sistema sbaglia tutti i tentativi di un tipo.

Probe	Genuini	Impostori	FR	FA	FRR	FAR
100	90	10	10	10	10/90 = 0,11	10/10 = 1
100	50	50	10	10	10/50 = 0,2	10/50 = 0,2
100	10	90	10	10	10/10 = 1	10/90 = 0,11

A parità di probe e di risposte sbagliate, le tre situazioni sono molto diverse: il sistema sbaglia in quantità diverse e in direzioni diverse. Con 10 impostori su 100 li accetta tutti; con 10 genuini su 100 li respinge tutti. Eppure in tutti e tre i casi l'accuratezza è dell'80%. Non ci si può accontentare di questo valore, perché bisogna valutare in quale direzione vanno soprattutto gli errori: è lo stesso motivo per cui in biometria si usano FAR e FRR al posto dell'accuratezza (Sezione 2.3.2).

Capitolo 4

Affidabilità del riconoscimento

Gli indici di prestazione dei Capitoli 2 e 3 descrivono un sistema in media; questo capitolo guarda oltre la media, fino all'affidabilità di una singola risposta.

4.1 Dalla matrice delle distanze alle figures of merit

4.1.1 Simmetria della matrice

Come nel Capitolo 3, tutto parte dalla matrice delle distanze M (*distance matrix*, DM): per ogni coppia formata da un probe e da un template della gallery si calcola la distanza e la si scrive nella cella $M_{i,j}$, dove i è la riga del probe e j la colonna del template. Se il test è ALL-against-ALL (Sezione 3.6), cioè ogni template si confronta con tutti gli altri, e la misura di distanza è simmetrica, la matrice è simmetrica, $M_{i,j} = M_{j,i}$, e ha la diagonale nulla, $M_{i,i} = 0$.

Le proprietà che una distanza deve avere sono fissate dalla definizione di metrica. Una **metrica** (*metric*) su un insieme X è una funzione d che associa un numero reale a ogni coppia di elementi di X e che, per tutti gli x, y e z di X, rispetta quattro condizioni:

- $d(x, y) \geq 0$ (*non-negativity*, non negatività): una distanza non è mai negativa;
- $d(x, y) = 0$ se e solo se $x = y$ (*identity of indiscernibles*, identità degli indiscernibili): la distanza è nulla tra un elemento e se stesso, e solo in quel caso;
- $d(x, y) = d(y, x)$ (*symmetry*, simmetria): l'ordine dei due elementi non conta;
- $d(x, z) \leq d(x, y) + d(y, z)$ (*triangle inequality*, disuguaglianza triangolare): andare direttamente da x a z non costa mai più che passare per y.

Una **semimetrica** (*semimetric*) rispetta le prime tre condizioni, ma non necessariamente la disuguaglianza triangolare. Alla matrice bastano queste tre: la simmetria la rende simmetrica, e la seconda condizione ne annulla la diagonale, dove ogni template si confronta con se stesso.

Se la misura non è simmetrica, cioè per qualche coppia $d(x, y) \neq d(y, x)$ perché il risultato cambia secondo quale dei due elementi fa da probe, la si rende simmetrica

facendo la media delle due direzioni:

$$d^*(x,y) = d^*(y,x) = \frac{d(x,y) + d(y,x)}{2}.$$

4.1.2 Le figures of merit

Dalla matrice delle distanze si ricavano molti indici di prestazione, che si chiamano spesso **figures of merit** (FoM, figure di merito). Il tasso di false accettazioni (FAR, *False Acceptance Rate*) e quello di falsi rifiuti (FRR, *False Rejection Rate*), ad esempio, si calcolano come nella verifica single-template (Sezione 3.6.2): per ogni soglia si scorrono tutte le celle, si contano le false accettazioni e i falsi rifiuti e si dividono per il numero di coppie da impostore e di coppie genuine. La soglia scorre a passo fisso su tutto l'intervallo delle distanze, ad esempio da 0 a 1 ogni 0,005 se le distanze sono normalizzate tra 0 e 1, e ogni soglia dà un punto delle curve di FAR e FRR. Da queste si ricavano l'EER (*Equal Error Rate*) e la curva ROC (*Receiver Operating Characteristic*) della Sezione 2.3; dalla stessa matrice si ottengono anche la curva CMC (*Cumulative Match Characteristic*) e le distribuzioni degli score genuini e impostori.

4.1.3 Decidability

Un indice che non dipende dalla soglia è la **decidability** (decidibilità) d', che misura quanto sono separate le distribuzioni delle distanze genuine e di quelle impostore. La Figura 2.3 mostra due distribuzioni di questo tipo, con le similarità al posto delle distanze. Confrontando ogni campione con tutti gli altri, come nella matrice ALL-against-ALL (Figura 3.4), si ottengono due insiemi di dissimilarità, cioè di distanze:

- D^I, le distanze intra-classe, tra campioni dello stesso soggetto;
- D^E, le distanze inter-classe, tra campioni di soggetti diversi.

La decidability è

$$d' = \frac{|\operatorname{avg}(D^I) - \operatorname{avg}(D^E)|}{\sqrt{\frac{1}{2}\left(\operatorname{std}(D^I)^2 + \operatorname{std}(D^E)^2\right)}},$$

dove avg è la media di un insieme di valori e std la sua **deviazione standard**, che misura quanto i valori si allontanano dalla media: si fa la media dei quadrati degli scarti dalla media e se ne prende la radice. Con le due distanze 0,15 e 0,25, ad esempio, la media è 0,20, gli scarti sono $-0{,}05$ e $+0{,}05$, la media dei loro quadrati è 0,0025 e la deviazione standard è $\sqrt{0{,}0025} = 0{,}05$.

Il numeratore è la distanza tra le due medie. Il denominatore è la radice della media dei quadrati delle due deviazioni standard, una deviazione standard comune alle due distribuzioni: se sono uguali, coincide con ciascuna di esse. d' dice quindi quante deviazioni standard separano le due medie. Vale 0 se le medie coincidono, e più è alto, meno le due distribuzioni si sovrappongono e più è facile trovare una soglia che separi genuini e impostori. Per questo si usa per classificare i sistemi, ad esempio in una competizione, dal valore più alto (il migliore) al più basso.

4.1.4 CMC e ROC

La CMC è legata direttamente alla ROC, intesa come compromesso tra FAR e FRR al variare della soglia. È legata anche a FAR e FRR del matcher 1:1, quello che confronta il probe con un template alla volta e i cui score servono a ordinare i candidati. Ne segue che, quando l'identificazione si limita a ordinare dal migliore al peggiore gli score di un matcher 1:1, la CMC non aggiunge informazione rispetto alle curve di FAR e FRR: è solo un altro modo di mostrare gli stessi dati, e si può calcolare da quelle curve. Il rank del genuino dipende infatti da quanti impostori ottengono uno score migliore del suo: quanto spesso un impostore raggiunge un certo score lo dice il FAR, come si distribuiscono gli score genuini lo dice il FRR.

4.2 Che cosa non dicono gli indici globali

In pratica l'identificazione è molto più difficile della verifica, per i sistemi biometrici come per gli operatori umani, e per non fare confusione bisogna ragionare con il compito giusto e con le sue statistiche (Sezione 2.6).

Anche usati nel modo giusto, indici come FAR, FRR e CMS (*Cumulative Match Score*) non bastano a valutare a fondo un algoritmo. Sono misure *ex post*, calcolate sui risultati di un test, dopo un addestramento fatto prima (*ex ante*) su dataset limitati. I dataset sono stati il motore principale dei progressi del riconoscimento, come fonte di dati per l'addestramento e come banco di prova per confrontare gli algoritmi. Un dataset, però, può diventare un mondo chiuso, e la ricerca può ridursi a battere l'ultimo risultato su quel dataset, perdendo di vista il mondo reale che doveva rappresentare: è il problema del *dataset bias* (distorsione dovuta al dataset). Inoltre il contesto in cui il sistema funziona può essere diverso da quello del test, o cambiare nel tempo, e con il contesto cambiano le distribuzioni degli score (Figura 2.3), quindi anche FAR e FRR a una data soglia.

Per confrontare in modo affidabile due sistemi bisogna quindi considerare:

- quanti dataset si sono usati e con quali caratteristiche;
- la dimensione delle immagini;
- la dimensione del probe set e della gallery;
- quante e quali variazioni (di posa, di illuminazione...) il sistema affronta e quanto le tollera;
- l'eventuale interoperabilità, ad esempio la capacità di generalizzare a dataset diversi da quello di addestramento (*cross-dataset generalization*).

4.3 Il Doddington zoo

Nella Sezione 3.5.2 si è visto che anche la scelta di genuini e impostori può influire sui risultati di una valutazione. Il motivo è che gli utenti non si comportano tutti allo stesso modo, e alcuni causano molti più errori di altri. Il **Doddington zoo** classifica gli utenti secondo il comportamento dei loro score. In questa sezione gli score sono similarità: più sono alti, più due campioni si somigliano.

4.3.1 Quattro tipi di utenti

In ogni confronto ci sono due ruoli: chi presenta il campione, che fa da probe, e il proprietario del template con cui lo si confronta. Nella matrice degli score il primo corrisponde alla riga, il secondo alla colonna (Sezione 3.6). Il Doddington zoo distingue quattro tipi di utenti:

- *sheep* (pecore): i loro campioni somigliano molto agli altri propri campioni e poco a quelli degli altri, quindi causano meno false accettazioni e meno falsi rifiuti della media. È il comportamento normale;
- *goats* (capre): i loro campioni somigliano poco agli altri propri campioni. Gli score genuini bassi portano a un tasso di falsi rifiuti più alto della media;
- *lambs* (agnelli): sono facili da imitare. Quando il loro template si confronta con il campione di un'altra persona, lo score è più alto della media, quindi le false accettazioni sono più probabili;
- *wolves* (lupi): sono bravi a imitare gli altri. Quando presentano il proprio campione, hanno una probabilità più alta della media di ottenere uno score alto con il template di un'altra persona.

Agnelli e lupi portano allo stesso errore, la falsa accettazione, ma da parti opposte del confronto: l'agnello è la vittima e ha score alti lungo la sua colonna, il lupo è l'attaccante e li ha lungo la sua riga.

4.3.2 La biometric menagerie

Goats, lambs e wolves si definiscono con uno solo dei due tipi di score di un utente, i genuini o gli impostori. La *biometric menagerie* (serraglio biometrico) aggiunge quattro animali definiti su entrambi. Per un utente k si considerano due medie:

- $\bar{G}_k$ (G come *genuine*), la media dei suoi score genuini, ottenuti confrontando un suo campione con un suo template;
- $\bar{I}_k$ (I come *impostor*), la media dei suoi score impostori, che comprendono entrambe le direzioni: un campione di k confrontato con il template di un altro utente, e il campione di un altro utente confrontato con il template di k. Nella matrice sono la riga e la colonna di k, fuori dalla diagonale.

Proprio perché $\bar{I}_k$ mette insieme le due direzioni, agnelli e lupi finiscono nella stessa zona del piano formato dalle due medie, quella con $\bar{I}_k$ alto. I quattro animali nuovi stanno invece agli angoli del piano (Figura 4.1):

- *chameleons* (camaleonti), con $\bar{G}_k$ e $\bar{I}_k$ alti: sembrano simili a tutti. Causano raramente falsi rifiuti, ma facilmente false accettazioni. Può esserlo chi ha feature molto comuni, a cui l'algoritmo di matching dà molto peso;
- *phantoms* (fantasmi), con $\bar{G}_k$ e $\bar{I}_k$ bassi: possono causare falsi rifiuti, difficilmente false accettazioni. Può essere il caso di chi ha difficoltà nell'enrollment, e quindi feature estratte male;

- *doves* (colombe), con $\bar{G}_k$ alto e $\bar{I}_k$ basso: sono gli utenti migliori, un'estensione delle sheep, e sono raramente coinvolti in un errore di verifica. Può esserlo chi ha una caratteristica rara e distintiva, come un naso molto particolare;
- *worms* (vermi), con $\bar{G}_k$ basso e $\bar{I}_k$ alto: sono gli utenti peggiori. Hanno poche caratteristiche distintive e, se ci sono, causano una quota sproporzionata degli errori. È difficile immaginarli in un'applicazione reale: se molti utenti si comportano così, probabilmente l'algoritmo di matching ha un difetto di fondo.

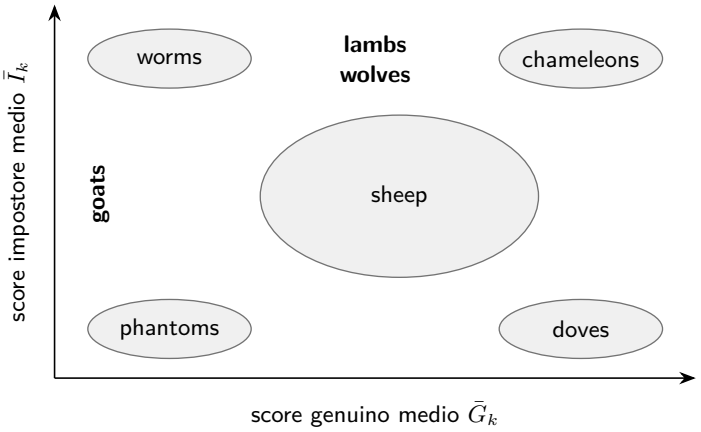


Figura 4.1. Gli utenti nel piano dello score genuino medio $\bar{G}_k$ e dello score impostore medio $\bar{I}_k$. Goats, lambs e wolves dipendono da uno solo dei due valori e stanno lungo i bordi; i quattro animali definiti su entrambi stanno agli angoli.

4.4 Affidabilità di una singola risposta

Anche quando le figures of merit globali sono buone, non tutte le risposte di un sistema sono ugualmente affidabili. Può cambiare la qualità dell'input: un volto con gli occhiali scuri, un'impronta sbiadita, una registrazione della voce con molto rumore di fondo. E può cambiare l'accuratezza della procedura di riconoscimento. Una misura dell'affidabilità di ogni singola risposta dà un'informazione in più, che serve

- a stabilire una politica di funzionamento: se un'identificazione non è abbastanza affidabile, e se è possibile, si ripete l'acquisizione;
- a fondere le risposte di sistemi diversi, nelle architetture multibiometriche (Sezione 1.7).

4.5 Misure di qualità del campione

Si può misurare la qualità del campione in ingresso prima del riconoscimento, per scartare a priori i campioni troppo distorti, che porterebbero a una risposta sbagliata o poco affidabile. È un'estensione del controllo di qualità che si fa durante l'enrollment (Sezione 1.4).

4.5.1 Misure generali

Alcune misure guardano la qualità dell'immagine in generale. La prima è la correlazione con un'immagine «media»: si costruisce un template medio da tutti i volti di addestramento, la sua qualità fa da riferimento, e si misura quanto il campione è correlato con esso. La correlazione coglie il degrado delle forme generali dell'immagine, ma non la perdita dei dettagli fini, che si misura con la seconda, la stima della **nitidezza** (*sharpness*): un'immagine sfocata (*blurred*) ha perso i dettagli ad alta frequenza, cioè i cambiamenti rapidi di intensità tra pixel vicini, come i bordi netti e le trame fini.

L'**Universal Image Quality Index** (UIQI, indice universale di qualità dell'immagine) vede ogni distorsione di un'immagine come una combinazione di tre fattori: perdita di correlazione, distorsione della luminanza e distorsione del contrasto. Confronta l'immagine originale x con l'immagine da valutare y, viste come due sequenze dei livelli di grigio degli N pixel, $x = \{x_1, \ldots, x_N\}$ e $y = \{y_1, \ldots, y_N\}$:

$$Q = \frac{4\,\sigma_{xy}\,\bar{x}\,\bar{y}}{(\sigma_x^2 + \sigma_y^2)\,(\bar{x}^2 + \bar{y}^2)},$$

dove

- $\bar{x}$ e $\bar{y}$ sono le medie dei livelli di grigio, cioè la luminosità media delle due immagini, e riguardano la luminanza;
- σ_x^2 e σ_y^2 sono le varianze, cioè i quadrati delle deviazioni standard σ_x e σ_y (Sezione 4.1.3): dicono quanto i livelli di grigio si allontanano dalla media, e riguardano il contrasto;
- σ_{xy} è la covarianza, la media dei prodotti degli scarti dalle due medie, pixel per pixel, come al numeratore della correlazione di Pearson (Sezione 2.2): dice se i livelli delle due immagini salgono e scendono insieme, e riguarda la correlazione.

Q vale 1 solo se le due immagini coincidono, e cala quando si perde correlazione o cambiano la luminosità media o il contrasto.

La **Sharpness Estimation** (SE, stima della nitidezza) misura la nitidezza di un'immagine di $x \times y$ pixel, dove qui x e y sono il numero di colonne e di righe, con la media delle differenze di intensità tra pixel vicini, in orizzontale e in verticale:

$$\mathrm{SE} = \frac{1}{2}\left(\frac{1}{(x-1)\,y}\sum_{m=1}^{y}\sum_{n=1}^{x-1}|p_{n,m} - p_{n+1,m}| + \frac{1}{(y-1)\,x}\sum_{m=1}^{y-1}\sum_{n=1}^{x}|p_{n,m} - p_{n,m+1}|\right),$$

dove $p_{n,m}$ è l'intensità del pixel nella colonna n e nella riga m. Il primo termine somma la differenza, in valore assoluto, tra ogni pixel e quello alla sua destra, e la divide per il numero di queste coppie: $x - 1$ in ciascuna delle y righe. Il secondo fa lo stesso tra ogni pixel e quello sotto. SE è la media dei due. In un'immagine sfocata i pixel vicini si somigliano, le differenze sono piccole e SE è bassa.

4.5.2 Misure per il volto

Per un volto si possono misurare le sue distorsioni tipiche: la posa, l'illuminazione e la simmetria. La posa si descrive con tre rotazioni della testa:

- *yaw* (imbardata), la rotazione attorno all'asse verticale, come quando si gira la testa per dire «no»;
- *pitch* (beccheggio), la rotazione attorno all'asse che va da un orecchio all'altro, come quando si annuisce;
- *roll* (rollio), la rotazione attorno all'asse che attraversa la testa da davanti a dietro, come quando la si inclina verso una spalla.

Il primo indice, **SP**, misura la distorsione della posa rispetto a quella frontale:

$$\mathrm{SP} = \alpha \cdot (1 - \mathit{roll}) + \beta \cdot (1 - \mathit{yaw}) + \gamma \cdot (1 - \mathit{pitch}),$$

dove *roll*, *yaw* e *pitch* misurano quanto il volto è ruotato in ciascuna direzione (0 se non lo è affatto) e α, β e γ sono i pesi delle tre rotazioni: più il volto è frontale, più SP è alto. Le rotazioni si stimano da punti del volto: il roll dall'inclinazione della linea che unisce gli occhi, lo yaw dalle distanze dei due occhi dalla punta del naso, che in un volto frontale sono uguali, il pitch da due distanze verticali, sopra e sotto la punta del naso.

Il secondo, **SI**, misura l'omogeneità dei livelli di grigio in alcune regioni del volto fissate in anticipo, come le guance:

$$\mathrm{SI} = 1 - F(\mathrm{std}(\mathit{mc})),$$

dove *mc* raccoglie i livelli di grigio medi delle regioni, std ne calcola la deviazione standard e F normalizza il risultato. Con una luce uniforme le regioni hanno livelli medi simili, la deviazione standard è bassa e SI è alto; una luce laterale schiarisce un lato del volto e scurisce l'altro, e SI scende.

Il terzo, **SY**, misura la simmetria del volto:

$$\mathrm{SY} = \sum_{(i,j) \in X} \mathrm{sym}(P_i, P_j),$$

dove X è l'insieme delle coppie (i, j) di punti corrispondenti sui due lati del volto, ad esempio lungo il contorno destro e quello sinistro, e $\mathrm{sym}(P_i, P_j)$ misura quanto i due punti P_i e P_j di una coppia sono simmetrici. In un volto ripreso di fronte i punti di ogni coppia sono simmetrici; se la testa è girata, non lo sono più.

4.5.3 Come si valuta una misura di qualità

Le misure di qualità si mettono alla prova su dataset di volti acquisiti in condizioni diverse, come FERET (volti frontali in condizioni controllate), LFW (*Labeled Faces in the Wild*, volti in condizioni non controllate) e SCface (volti ripresi da cinque telecamere, alla distanza maggiore).

Il primo test guarda come si distribuiscono i valori di una misura sulle immagini di un dataset, e dice qual è la qualità media di quel dataset secondo quella misura.

Due o più misure si confrontano calcolando quanto i loro valori sono correlati sulle stesse immagini.

Il secondo test guarda l'effetto sulle prestazioni del sistema. Si fissa una soglia di tolleranza sulla qualità, si scartano i campioni che non la raggiungono e si calcola l'EER su quelli rimasti; alzando la soglia, i campioni considerati adeguati diminuiscono e l'errore di solito cala. Una buona misura di qualità fa scendere molto l'errore scartando il minor numero possibile di campioni.

4.6 Margine dalla stima degli errori

Un'altra misura di affidabilità parte dalle stime degli errori, FAR e FRR, in funzione della soglia t (Sezione 2.3). Il **margine** è

$$\mathcal{M}(t) = |\,\mathrm{FAR}(t) - \mathrm{FRR}(t)|,$$

e per una singola risposta si calcola con la soglia pari allo score ottenuto, che qui è una similarità. Il suo andamento si legge nella Figura 2.3, a destra. Vicino al punto in cui le due curve si incrociano, l'EER, FAR e FRR si equivalgono e il margine è quasi 0: lo score cade dove genuini e impostori si confondono, e la decisione è incerta. Allontanandosi da quel punto uno dei due errori prevale e il margine cresce verso 1: quasi nessun impostore arriva a uno score molto alto, e quasi nessun genuino scende a uno molto basso, quindi la decisione è sicura.

4.7 System Response Reliability

4.7.1 Qualità e affidabilità

Una misura di qualità del campione e una misura di affidabilità della risposta sono cose molto diverse. La foto perfetta, frontale e ben illuminata, di una persona molto simile a un altro soggetto registrato ha una qualità alta, ma la risposta è incerta, perché i due candidati sono quasi alla stessa distanza dal probe. La foto un po' sfocata di una persona dai tratti molto distintivi ha una qualità più bassa, ma la risposta può essere affidabile, perché il primo candidato è molto più vicino di tutti gli altri.

L'indice di **System Response Reliability** (SRR, affidabilità della risposta del sistema), con valori tra 0 e 1, misura quanto un sistema di identificazione riesce a separare i genuini dagli impostori, probe per probe. In questa sezione si usano le distanze, e si assume che il risultato di un'identificazione sia l'intera gallery ordinata per distanza crescente dal probe, o almeno una lista breve dei primi candidati. L'idea è guardare la «nuvola» di candidati attorno al soggetto restituito: se pochi template sono vicini al probe quasi quanto il primo, la risposta è affidabile; se sono tanti, il sistema può confonderli e la risposta lo è meno. L'SRR si costruisce su una funzione $\varphi(p)$ del probe p che misura questa confusione, in due versioni: la relative distance e la density ratio.

4.7.2 Relative distance e density ratio

Siano $g_{i_1}, g_{i_2}, \ldots, g_{i_{|G|}}$ i template della gallery G in ordine di distanza crescente dal probe: g_{i_1} è il più vicino, cioè il soggetto restituito, g_{i_2} il secondo e $g_{i_{|G|}}$ il più lontano, dove $|G|$ è il numero di template della gallery. Entrambe le funzioni applicano alle distanze $d(p, g)$ una funzione F, ad esempio per normalizzarle; nell'esempio che segue F le lascia invariate.

La **relative distance** (distanza relativa) confronta il distacco tra i primi due candidati con la distanza del più lontano:

$$\varphi(p) = \frac{F(d(p, g_{i_2})) - F(d(p, g_{i_1}))}{F(d(p, g_{i_{|G|}}))}.$$

Più il distacco è piccolo rispetto al denominatore, più i primi due candidati si possono confondere, e meno la risposta è affidabile.

La **density ratio** (rapporto di densità) conta invece i template che cadono vicino al primo, in una finestra che arriva al doppio della sua distanza dal probe:

$$\varphi(p) = 1 - \frac{|N_b|}{|G|},$$

dove $|N_b|$ è il numero di template nella finestra, cioè con una distanza dal probe, trasformata da F, minore del doppio di quella del primo. Sia $|N_b|$ sia $|G|$ si contano senza il primo elemento della lista: così, se nessun altro template cade nella finestra, $\varphi(p)$ vale esattamente 1, il suo massimo.

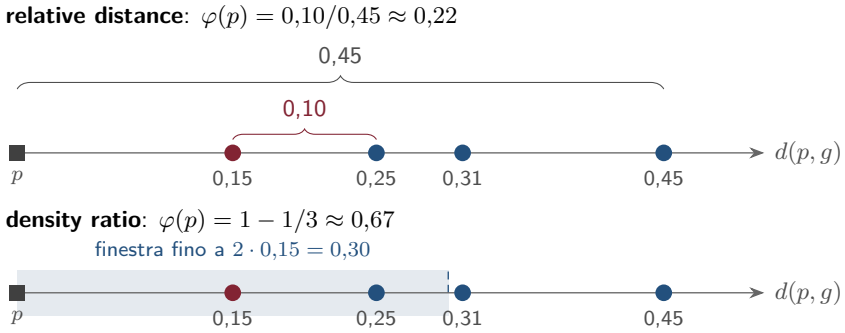


Figura 4.2. Le distanze dal probe p dei quattro template dell'esempio, con il più vicino in rosso. In alto la relative distance confronta il distacco tra i primi due con la distanza del più lontano; in basso la density ratio conta i template nella finestra, escluso il primo.

Esempio (relative distance e density ratio). Le distanze dal probe dei quattro template della gallery, in ordine, sono 0,15, 0,25, 0,31 e 0,45 (Figura 4.2).

- Relative distance: il distacco tra i primi due è $0{,}25 - 0{,}15 = 0{,}10$ e la distanza massima è 0,45, quindi $\varphi(p) = 0{,}10/0{,}45 \approx 0{,}22$.
- Density ratio: la finestra arriva a $2 \cdot 0{,}15 = 0{,}30$. Escluso il primo restano tre template, e solo quello a 0,25 cade nella finestra: $|N_b| = 1$, $|G| = 3$ e $\varphi(p) = 1 - 1/3 \approx 0{,}67$.

La density ratio è meno sensibile ai valori anomali (*outlier*) e di solito funziona meglio. La relative distance divide per la distanza massima, e basta un solo template lontanissimo, ad esempio acquisito male, per abbassarla con qualunque probe; la density ratio guarda solo i template vicini al primo. Ha però un difetto: la finestra dipende dalla distanza del primo candidato. Se il primo è vicino al probe la finestra è stretta; se è lontano la finestra è larga, e ci si può aspettare che sia comunque più affollata. Sostituire il 2 con un parametro che si adatta non ha dato risultati migliori.

4.7.3 Valore critico e indice SRR

Per usare $\varphi(p)$ serve un **valore critico**, un unico valore indicato con φ_k, che separi le risposte da confermare da quelle da non confermare. Se $\varphi(p) > \varphi_k$ la risposta è confermata e il probe si considera un genuino; se $\varphi(p) < \varphi_k$ non lo è, e il probe si considera un impostore. Il valore critico si sceglie offline, su probe di cui si conosce la ground truth, guardando le risposte che il sistema ha accettato: le accettazioni genuine (GA) e le false accettazioni (FA). φ_k è il valore che rende minima la somma delle due stime sbagliate di $\varphi(p)$ (Tabella 4.1).

Tabella 4.1. Le risposte accettate dal sistema, divise secondo la verità e secondo il confronto tra $\varphi(p)$ e il valore critico φ_k. In rosso le due stime sbagliate, di cui φ_k rende minima la somma.

	$\varphi(p) > \varphi_k$: risposta confermata	$\varphi(p) < \varphi_k$: risposta non confermata
Accettazione genuina (GA)	corretto	errore: un genuino riconosciuto correttamente non viene confermato
Falsa accettazione (FA)	errore: un impostore riconosciuto per errore viene confermato	corretto: la falsa accettazione viene scoperta

Più $\varphi(p)$ è lontano da φ_k, più la risposta è affidabile. Perché l'indice vada da 0 a 1 da entrambe le parti, la distanza tra i due si divide per l'ampiezza S dell'intervallo che va da φ_k all'estremo dalla parte di $\varphi(p)$, nell'intervallo $[0, 1)$ dei valori possibili:

$$S(\varphi(p), \varphi_k) = \begin{cases} 1 - \varphi_k & \text{se } \varphi(p) > \varphi_k, \\ \varphi_k & \text{altrimenti.} \end{cases}$$

L'indice SRR è quindi

$$\mathrm{SRR} = \frac{|\varphi(p) - \varphi_k|}{S(\varphi(p), \varphi_k)}.$$

Con $\varphi_k = 0{,}40$, ad esempio, un valore $\varphi(p) = 0{,}85$ sta sopra, $S = 0{,}60$ e $\mathrm{SRR} = 0{,}45/0{,}60 = 0{,}75$; un valore $\varphi(p) = 0{,}05$ sta sotto, $S = 0{,}40$ e $\mathrm{SRR} = 0{,}35/0{,}40 = 0{,}875$. L'SRR vale quindi 0 quando $\varphi(p)$ coincide con il valore critico, ed è alto sia quando $\varphi(p)$ è molto sopra φ_k, e il probe è con buona sicurezza un genuino, sia quando è molto sotto, e il probe è con buona sicurezza un impostore.

4.7.4 Una soglia per l'SRR

In un'architettura multibiometrica ogni sistema i ha la sua soglia di affidabilità th_i: una sua risposta si considera abbastanza affidabile se l'SRR la supera. La soglia si stima in modo automatico dagli SRR delle ultime risposte del sistema, raccolti nel vettore $\bar{S}_i$, da non confondere con l'ampiezza S appena vista. Si vuole che questi valori abbiano una media alta, perché il sistema è in generale affidabile, e una variabilità bassa, perché il sistema è stabile. La formula riassume le due esigenze:

$$th_i = \left| \frac{\mathrm{E}[\bar{S}_i]^2 - \sigma[\bar{S}_i]}{\mathrm{E}[\bar{S}_i]} \right|,$$

dove $\mathrm{E}[\bar{S}_i]$ è la media degli SRR raccolti e $\sigma[\bar{S}_i]$ la loro deviazione standard. Dividendo per la media ciascun termine del numeratore, l'espressione dentro il valore assoluto diventa $\mathrm{E}[\bar{S}_i] - \sigma[\bar{S}_i]/\mathrm{E}[\bar{S}_i]$: la soglia sta poco sotto la media degli SRR recenti, tanto più sotto quanto più i valori oscillano.

4.8 Aggiornamento dei template

Una delle soluzioni possibili per migliorare qualità e affidabilità è aggiornare i template. Il template (Sezione 1.4) si etichetta con l'identità della persona; non dovrebbe permettere di ricostruire un campione valido, e le sue dimensioni ridotte permettono di codificarlo e di memorizzarlo su più dispositivi. Ogni volta che una persona fornisce un campione se ne ottiene un template diverso.

Durante il funzionamento il sistema acquisisce nel tempo molti più dati biometrici di quelli dell'enrollment, e può usarli per aggiornare regolarmente i template della gallery. Gli scopi sono due: contrastare l'invecchiamento dei template (*template ageing*), perché il tratto cambia nel tempo (Sezione 1.9), e migliorarli (*template enhancing*).

Le scelte da fare sono due. La prima è chi assegna l'etichetta d'identità ai dati nuovi:

- nei sistemi *supervised* (supervisionati) la assegna un supervisore durante il funzionamento, e di solito l'aggiornamento avviene offline;
- nei sistemi *semi-supervised* (semi-supervisionati) si usano insieme dati etichettati e non etichettati, sia online sia offline.

La seconda è quando selezionare i template più rappresentativi:

- *online*, appena il sistema acquisisce un dato nuovo;
- *offline*, dopo aver raccolto una certa quantità di dati in un periodo di tempo.